UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO

FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA

ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

"DESARROLLO DE UN MODELO DE APRENDIZAJE AUTOMÁTICO PARA LA DETECCIÓN DE ACOSO SEXUAL EN RELATOS DE ESTUDIANTES DE LA UNSAAC"

Para optar al título profesional de:

Ingeniero Informático y de Sistemas

Presentado por:

Br. Pamela Diaz Misme

ORCID: 0009-0006-8710-4858

Asesor:

Dr. Rony Villafuerte Serna

ORCID: 0000-0003-4607-522X

CUSCO – PERÚ

2026

Resumen

En la Universidad Nacional de San Antonio Abad del Cusco (UNSAAC), casi ninguna experiencia de hostigamiento sexual llega a convertirse en denuncia formal. Muchas de estas situaciones quedan registradas solo como relatos escritos, y reconocer en ellos un caso de acoso exige una lectura cuidadosa, porque no siempre se describen con palabras explícitas. Esta investigación propone desarrollar un modelo de aprendizaje automático que, a partir de un relato escrito por un estudiante, determine si describe o no una situación de acoso sexual. Para ello se construirá un corpus de relatos aportados de forma voluntaria por estudiantes mayores de edad, que serán anonimizados y etiquetados por dos anotadores siguiendo una guía revisada por especialistas. El desarrollo seguirá la metodología CRISP-DM. Como modelos candidatos se entrenarán la regresión logística, la máquina de vectores de soporte y Naïve Bayes con representación TF-IDF, además del modelo BETO ajustado para el español. Todo el procesamiento se hará en equipos locales y cuidando que los datos de prueba no intervengan en el entrenamiento. El modelo elegido se comparará con una línea base léxica, basada en palabras clave, usando macro F1, precisión y exhaustividad, junto con la prueba de McNemar. La investigación es aplicada, de tipo tecnológico, con enfoque cuantitativo y diseño experimental. Como resultado se obtendrá un modelo validado y un prototipo que muestra la predicción y las palabras que más influyeron en ella, pensado como apoyo para el personal que revisa estos casos y no como sustituto de su criterio.

Palabras clave: acoso sexual, aprendizaje automático, procesamiento del lenguaje natural, clasificación de textos, educación superior.

Abstract

At the Universidad Nacional de San Antonio Abad del Cusco (UNSAAC), almost no experience of sexual harassment ends up as a formal complaint. Many of these situations are recorded only as written narratives, and recognizing harassment in them requires careful reading, since it is not always described in explicit terms. This research proposes to develop a machine learning model that, given a narrative written by a student, determines whether it describes a situation of sexual harassment. A corpus of narratives voluntarily contributed by adult students will be built, anonymized, and labeled by two annotators following a guide reviewed by specialists. Development will follow the CRISP-DM methodology. Logistic regression, support vector machine, and Naïve Bayes with TF-IDF representation will be trained as candidate models, along with the BETO model fine-tuned for Spanish. All processing will run on local machines, making sure that test data never take part in training. The chosen model will be compared with a keyword-based lexical baseline using macro F1, precision, and recall, together with McNemar's test. The research is applied and technological, with a quantitative approach and an experimental design. The outcome will be a validated model and a prototype that shows the prediction and the words that most influenced it, intended to support the staff who review these cases rather than to replace their judgment.

Keywords: sexual harassment, machine learning, natural language processing, text classification, higher education.

Índice General

Resumen II

Abstract III

Índice General IV

Índice de Tablas VII

Índice de Figuras VIII

Índice de Algoritmos IX

Índice de Ecuaciones X

Índice de Anexos XI

Listado de Abreviaturas XII

Glosario de Términos XIII

Introducción XIV

1. Aspectos Generales **1**
- 1.1. Planteamiento del Problema . . . 1
  - 1.1.1. Descripción del problema . . . 1
  - 1.1.2. Identificación del problema . . . 2
- 1.2. Formulación del Problema . . . 3
  - 1.2.1. Problema general . . . 3
  - 1.2.2. Problemas específicos . . . 3
- 1.3. Objetivos . . . 3
  - 1.3.1. Objetivo general . . . 3
  - 1.3.2. Objetivos específicos . . . 4
- 1.4. Justificación . . . 4
  - 1.4.1. Conveniencia . . . 4
  - 1.4.2. Relevancia . . . 4
  - 1.4.3. Implicancias prácticas . . . 5
  - 1.4.4. Valor teórico . . . 5
  - 1.4.5. Utilidad metodológica . . . 5
- 1.5. Delimitación de Estudio . . . 6
  - 1.5.1. Delimitación espacial . . . 6
  - 1.5.2. Delimitación temporal . . . 6
- 1.6. Hipótesis . . . 6
  - 1.6.1. Hipótesis general . . . 6
  - 1.6.2. Hipótesis específicas . . . 6
  - 1.6.3. Contraste de las hipótesis . . . 7

1.7. Variables . . . 8
1.7.1. Identificación de variables . . . 8
1.7.2. Operacionalización de variables . . . 9
1.8. Método . . . 10
1.8.1. Tipo . . . 10
1.8.2. Diseño . . . 10
1.8.3. Objeto de estudio, población y muestra . . . 11
1.8.4. Técnicas e instrumentos de recolección de datos . . . 12
1.8.5. Técnicas de procesamiento y análisis de datos . . . 12
1.8.6. Entorno de pruebas . . . 13
1.8.7. Consideraciones éticas . . . 13
1.8.8. Cronograma de actividades . . . 14
1.9. Presupuesto . . . 15

2. Marco Teórico **16**
2.1. Antecedentes . . . 16
2.1.1. Antecedentes internacionales . . . 17
2.1.2. Antecedentes nacionales . . . 25
2.1.3. Análisis comparativo de los antecedentes . . . 26
2.2. Bases Teóricas . . . 27
2.2.1. Acoso sexual y hostigamiento sexual . . . 27
2.2.2. Relatos y mensajes . . . 28
2.2.3. Desarrollo de modelos con CRISP-DM . . . 28
2.2.4. Representación de los textos . . . 28
2.2.5. Clasificadores supervisados . . . 29
2.2.6. Modelos basados en *transformers* . . . 30
2.2.7. Líneas base . . . 31
2.2.8. Desbalance de clases y fuga de información . . . 32
2.2.9. Métricas de evaluación . . . 33
2.2.10. Pruebas estadísticas para comparar modelos . . . 33
2.2.11. Explicabilidad . . . 34
2.2.12. Arquitectura cliente-servidor para el prototipo . . . 34
2.3. Tecnologías y Entornos de Desarrollo . . . 35
2.3.1. Bibliotecas de aprendizaje automático . . . 35
2.3.2. Tecnologías del prototipo . . . 36

3. Desarrollo de la Propuesta **37**
3.1. Metodología de Desarrollo . . . 37
3.2. Arquitectura de la Solución . . . 37
3.3. Etapas del Desarrollo . . . 38
3.3.1. Etapa 1: Construcción del corpus (OE1) . . . 38
3.3.2. Etapa 2: Entrenamiento y selección del modelo (OE2) . . . 39
3.3.3. Etapa 3: Validación del modelo (OE3) . . . 40
3.3.4. Etapa 4: Implementación del prototipo (OE4) . . . 40
3.4. Prototipo de Apoyo a la Revisión . . . 41
3.5. Resultados Esperados . . . 42

Conclusiones **43**

Recomendaciones **44**

Bibliografía **45**

Anexo A. Matriz de Consistencia **51**

Anexo B. Guía de Anotación **52**

Anexo C. Instrumento de Recolección **53**

Índice de Tablas

1 Árbol de problemas 2
2 Criterios de contraste de las hipótesis 8
3 Matriz de operacionalización de variables 9
4 Niveles de los factores del diseño experimental 11
5 Entorno de pruebas 13
6 Cronograma de actividades 14
7 Presupuesto de la investigación 15

8 Resumen de los antecedentes más cercanos 16
9 Tecnologías seleccionadas y criterio técnico de elección 35

10 Relación entre objetivos específicos, etapas de desarrollo y CRISP-DM . . 37
11 Requisitos funcionales del prototipo 41
12 Requisitos no funcionales del prototipo 41
13 Matriz de consistencia 51
14 Etiquetas y criterios de anotación 52

Índice de Figuras

1 Diagrama de Gantt de la investigación 15

2 Arquitectura de la solución 38
3 Etapas del desarrollo del modelo 38

Índice de Algoritmos

1 Entrenamiento, selección y validación del modelo 40

Índice de Ecuaciones

1 Hipótesis estadística general 7
2 Esquema del diseño experimental 11
3 Ponderación TF-IDF de un término 29
4 Regresión logística 29
5 Función de pérdida de la regresión logística 29
6 Problema de optimización de la SVM lineal 30
7 Clasificación con Naïve Bayes multinomial 30
8 Mecanismo de atención 30
9 Capa de clasificación sobre BERT 31
10 Regla de la línea base léxica 31
11 Peso de cada clase 32
12 Generación de ejemplos con SMOTE 32
13 Precisión, exhaustividad y F1 33
14 Macro F1 para dos clases 33
15 Coeficiente kappa de Cohen 33
16 Estadístico de McNemar 33
17 Valor de Shapley de una característica 34

Índice de Anexos

A Matriz de Consistencia 51
B Guía de Anotación 52
C Instrumento de Recolección 53

Listado de Abreviaturas

API	Interfaz de programación de aplicaciones (*Application Programming Interface*)
BERT	Representaciones codificadas bidireccionales de *transformers* (*Bidirectional Encoder Representations from Transformers*)
BETO	Modelo BERT preentrenado con textos en español
CRISP-DM	Proceso estándar intersectorial para minería de datos (*Cross-Industry Standard Process for Data Mining*)
EDOS	Conjunto de datos para la detección explicable de sexismo en línea (*Explainable Detection of Online Sexism*)
EXIST	Tarea compartida de identificación de sexismo en redes sociales (*sEXism Identification in Social neTworks*)
FN	Falso negativo
FP	Falso positivo
GPU	Unidad de procesamiento gráfico (*Graphics Processing Unit*)
HWE	Ambiente hostil (*Hostile Work Environment*)
IC	Intervalo de confianza
KNN	K vecinos más cercanos (*K-Nearest Neighbors*)
LDA	Asignación latente de Dirichlet (*Latent Dirichlet Allocation*)
PLN	Procesamiento del lenguaje natural
QPQ	Intercambio condicionado de favores sexuales (*Quid Pro Quo*)
SEQ	Cuestionario de experiencias sexuales (*Sexual Experiences Questionnaire*)
SHAP	Explicaciones aditivas de Shapley (*SHapley Additive exPlanations*)
SMOTE	Técnica de sobremuestreo sintético de la clase minoritaria (*Synthetic Minority Over-sampling Technique*)
SVM	Máquina de vectores de soporte (*Support Vector Machine*)
TF-IDF	Frecuencia de término – frecuencia inversa de documento (*Term Frequency – Inverse Document Frequency*)
UNSAAC	Universidad Nacional de San Antonio Abad del Cusco
VP	Verdadero positivo

Glosario de Términos

Acoso sexual	Conducta de naturaleza sexual no deseada que afecta la dignidad de la persona. En la normativa peruana se denomina hostigamiento sexual.
Adjudicación	Revisión de un especialista que resuelve los desacuerdos entre anotadores y fija la etiqueta final de un relato.
Ajuste fino	Entrenamiento adicional de un modelo preentrenado con datos etiquetados de una tarea específica (*fine-tuning*).
Anonimización	Proceso de retirar o reemplazar la información que permite identificar a una persona.
Anotación	Asignación de una etiqueta a cada relato siguiendo una guía con criterios explícitos.
Corpus	Conjunto organizado de textos que se usa para analizar y entrenar modelos.
Desbalance de clases	Situación en la que una clase tiene muchos más ejemplos que otra.
Exhaustividad	Proporción de los casos positivos reales que el modelo logra identificar (*recall*).
Fuga de información	Uso, durante el entrenamiento o la selección del modelo, de datos que debían reservarse para la evaluación.
Línea base	Modelo sencillo que sirve de punto de comparación para el modelo desarrollado.
Línea base léxica	Línea base que marca como acoso todo relato que contiene alguna palabra de una lista de términos sexuales.
Precisión	Proporción de los casos que el modelo marcó como positivos que realmente lo son.
Prototipo	Versión funcional de una aplicación que permite probar su utilidad antes de un desarrollo definitivo.
Relato	Texto que cuenta una experiencia, con referencias a lo que ocurrió, su contexto o sus consecuencias.
Sobreajuste	Situación en la que un modelo memoriza los datos de entrenamiento y falla con datos nuevos.
Validación cruzada	Procedimiento que divide los datos de desarrollo en pliegues para entrenar y validar el modelo varias veces.

Introducción

El acoso sexual en las universidades es un problema conocido, pero poco denunciado. Las relaciones de jerarquía, la costumbre de restar importancia a ciertas conductas y el temor a las consecuencias hacen que muchas personas prefieran callar (Bondestam & Lundqvist, 2020; Ríos-Albert et al., 2026). La UNSAAC no es ajena a esta realidad: en una encuesta aplicada a sus estudiantes, el 77,5 % reportó haber vivido al menos una manifestación de hostigamiento sexual, y menos del 1 % de quienes lo vivieron presentó una denuncia (Gutiérrez de Alarcón et al., 2022). La Ley N.º 27942 y su reglamento obligan a las universidades a prevenir y atender estos casos (Congreso de la República del Perú, 2003; Ministerio de la Mujer y Poblaciones Vulnerables, 2019), pero difícilmente se puede atender lo que no llega a conocerse.

Una parte de estas experiencias sí se cuenta, aunque no por la vía formal: aparece en testimonios, en conversaciones con tutores o en mensajes a las oficinas de orientación. Leer esos relatos y reconocer cuándo describen acoso no es sencillo, porque el significado de una situación depende del contexto y de la relación entre las personas, y muchas veces no hay una sola palabra que lo delate (Dutta et al., 2025; Salawu et al., 2020).

La forma más intuitiva de automatizar esa lectura sería buscar palabras clave, pero ese enfoque falla justo donde más importa: no reconoce el acoso que se cuenta sin términos explícitos y marca como acoso cualquier texto que los mencione. El aprendizaje automático ofrece otra salida. Un modelo entrenado con ejemplos etiquetados aprende qué combinaciones de palabras y qué contextos acompañan a un relato de acoso, y puede aplicar ese aprendizaje a relatos nuevos (Salawu et al., 2020). Los clasificadores clásicos, como la regresión logística o las máquinas de vectores de soporte, funcionan bien con pocos datos y son fáciles de interpretar; los modelos basados en *transformers*, como BETO, representan el significado de cada palabra según la oración en que aparece (Cañete et al., 2020; Devlin et al., 2019), aunque necesitan más cómputo. Por eso esta

tesis no elige uno de antemano: los compara en igualdad de condiciones. Esta idea ya se ha probado en otros contextos. Gorissen et al. (2023) identificaron revelaciones de victimización sexual en mensajes en neerlandés; Wijaya et al. (2022) clasificaron relatos de acoso académico según su tipo, y Mohammadi et al. (2024) detectaron sexismo en redes sociales con modelos *transformers*. En español también hay avances: Escobar Mercado et al. (2022) clasificaron automáticamente los testimonios de violencia sexual publicados con la etiqueta #Cuéntalo, Imbaquinga Guaña y Lara Anago (2025) detectaron mensajes de cibergrooming con un modelo integrado en un prototipo web, Cumba Armijos (2018) entrenó una red neuronal para detectar ciberacoso en tuits y, en el Perú, Aguirre Soto et al. (2022) aplicaron BERT para detectar ciberacoso en Twitter. Sin embargo, todos estos trabajos usan publicaciones de redes sociales o mensajes, no relatos de estudiantes universitarios, y algunos se evaluaron de una manera que puede inflar los resultados (Kapoor & Narayanan, 2023). En los antecedentes revisados no se encontró un modelo entrenado con relatos de estudiantes universitarios peruanos para detectar acoso sexual.

Esta tesis propone desarrollar ese modelo. La idea es simple de enunciar: dado un relato escrito por un estudiante, el modelo debe indicar si describe o no una situación de acoso sexual. Para lograrlo se construirá un corpus de 400 a 600 relatos aportados voluntariamente por estudiantes de la UNSAAC, anonimizados y etiquetados con una guía revisada por especialistas. Con ese corpus se entrenarán y compararán varios modelos, y el elegido se probará una sola vez con relatos de participantes que no intervinieron en el entrenamiento. Su desempeño se medirá con el macro F1, la precisión y la exhaustividad, y se comparará con una línea base léxica que solo busca palabras clave. Finalmente, el modelo se integrará en un prototipo que sirva de apoyo a las personas encargadas de revisar estos casos.

En ese marco, la investigación responde al siguiente problema general: ¿en qué medida el desarrollo de un modelo de aprendizaje automático permite la detección de acoso sexual en relatos de estudiantes de la UNSAAC, en comparación con una línea base de referencia? El objetivo general es desarrollar un modelo de aprendizaje automático para la detección de acoso sexual en relatos de estudiantes de la UNSAAC, cuyo desempeño se

evaluará mediante el macro F1 y la exhaustividad en relatos de prueba, frente a una línea base léxica. Para alcanzarlo se plantean cuatro objetivos específicos: construir un corpus anonimizado y anotado de relatos de estudiantes de la UNSAAC; entrenar y seleccionar el modelo con mejor desempeño, con y sin tratamiento del desbalance de clases; validar el modelo seleccionado frente a una línea base y analizar sus errores; e implementar un prototipo que aplique el modelo validado a nuevos relatos. La hipótesis general sostiene que el modelo de aprendizaje automático desarrollado detecta acoso sexual en relatos de estudiantes de la UNSAAC con un desempeño significativamente superior al de una línea base de referencia.

El valor de este trabajo es de tres tipos. En lo científico, aporta evidencia sobre qué tan bien aprende un modelo a reconocer el acoso en relatos en español y en qué casos se equivoca. En lo metodológico, deja un procedimiento para recolectar, anonimizar, etiquetar y evaluar textos sensibles sin que los datos de prueba se filtren en el entrenamiento. En lo tecnológico, entrega un modelo validado y un prototipo que la universidad podría usar como apoyo en sus oficinas de orientación.

El documento se organiza en tres capítulos. El primero presenta los aspectos generales: el problema, los objetivos, la justificación, la delimitación, las hipótesis, las variables y el método, es decir, qué se investiga y cómo se comprobará. El segundo reúne el marco teórico: los antecedentes que muestran el vacío, las bases matemáticas de los modelos y las métricas, y las tecnologías que se usarán. El tercero describe cómo se desarrollará la propuesta en cuatro etapas, una por cada objetivo específico, desde la recolección de los relatos hasta el prototipo. Al final se incluyen las conclusiones, las recomendaciones, la bibliografía y los anexos.

1. Aspectos Generales

1.1. Planteamiento del Problema

1.1.1. Descripción del problema

El acoso sexual en la universidad puede tomar muchas formas: comentarios, miradas, mensajes, insinuaciones, contacto físico o presiones a cambio de una nota. Algunas de estas conductas son evidentes; otras se mueven en zonas grises que la propia comunidad universitaria tiende a normalizar (Ríos-Albert et al., 2026). Lo que tienen en común es que rara vez se denuncian. En la revisión de Bondestam y Lundqvist (2020), el subregistro aparece como una constante en universidades de distintos países, ligado a las jerarquías y a la cultura del silencio.

En la UNSAAC, una encuesta aplicada en 2019 a 151 estudiantes encontró que el 77,5 % había experimentado al menos una manifestación de hostigamiento sexual, y que solo una de las 117 personas afectadas lo denunció (Gutiérrez de Alarcón et al., 2022). La muestra no es representativa, pero la diferencia entre lo que ocurre y lo que llega a las instancias formales es demasiado grande para pasarla por alto. Esto ocurre pese a que la Ley N.º 27942 y su reglamento exigen a las universidades prevenir, investigar y sancionar el hostigamiento sexual (Congreso de la República del Perú, 2003; Ministerio de la Mujer y Poblaciones Vulnerables, 2019).

Cuando estas experiencias se cuentan, suele ser por escrito: un testimonio, un mensaje a un tutor, un formulario de orientación. Reconocer en esos textos una situación de acoso requiere una lectura atenta. Muchas veces el relato no usa palabras sexuales explícitas, y otras veces las usa sin que exista acoso. Revisar manualmente un volumen grande de relatos toma tiempo y depende del criterio de cada lector.

El aprendizaje automático permite construir modelos que aprenden a clasificar textos a partir de ejemplos. Ya existen modelos de este tipo en inglés y en español,

pero se desarrollaron con publicaciones de redes sociales o mensajes, y muchos para fenómenos como el sexismo o el ciberacoso, que no son lo mismo que el acoso sexual (Cumba Armijos, 2018; Dutta et al., 2025; Escobar Mercado et al., 2022; Imbaquinga Guaña & Lara Anago, 2025; Salawu et al., 2020). Además, algunos de esos estudios se evaluaron con prácticas que pueden sobrestimar el rendimiento (Kapoor & Narayanan, 2023; Wijaya et al., 2022). No se cuenta hoy con un modelo entrenado y validado con relatos de estudiantes universitarios, y menos aún de la UNSAAC.

1.1.2. Identificación del problema

La Tabla 1 resume las causas y los efectos del problema.

Tabla 1
Árbol de problemas

Nivel	**Descripción**
Efectos	• Se usan cifras obtenidas con otros tipos de texto y en otros contextos como si fueran válidas para la UNSAAC. • No se sabe en qué casos fallaría un modelo ante expresiones locales, ironía o falta de contexto. • No existe una herramienta que apoye la revisión de relatos en la universidad.
Problema central	No existe un modelo de aprendizaje automático desarrollado y validado para detectar acoso sexual en relatos de estudiantes de la UNSAAC.
Causas	• No hay un corpus local de relatos anonimizados y etiquetados. • Los conjuntos de datos disponibles son publicaciones de redes sociales o tratan sexismo y ciberacoso, no relatos universitarios de acoso sexual. • El significado de un relato depende del contexto y de la relación entre las personas. • Los casos de acoso son minoría en los datos y es fácil evaluar mal un modelo.

Nota. Elaboración propia a partir de Salawu et al. (2020), Bondestam y Lundqvist (2020) y Dutta et al. (2025).

La unidad de análisis es el relato escrito en español sobre una interacción vivida en el entorno universitario, aportado de forma voluntaria por un estudiante matriculado

y mayor de edad. Cada relato se clasifica por lo que cuenta, no por quién lo escribe.

1.2. Formulación del Problema

1.2.1. Problema general

¿En qué medida el desarrollo de un modelo de aprendizaje automático permite la detección de acoso sexual en relatos de estudiantes de la UNSAAC, en comparación con una línea base de referencia?

1.2.2. Problemas específicos

PE1: ¿Qué nivel de acuerdo entre anotadores se alcanza al construir un corpus anonimizado y anotado de relatos de estudiantes de la UNSAAC para entrenar el modelo de aprendizaje automático?

PE2: ¿Qué modelo de aprendizaje automático, y con qué tratamiento del desbalance de clases, logra el mejor desempeño en la detección de acoso sexual al ser entrenado y seleccionado sin fuga de información?

PE3: ¿Qué desempeño alcanza el modelo seleccionado al validarlo en la detección de acoso sexual en relatos de estudiantes de la UNSAAC frente a una línea base de referencia, y qué errores comete?

PE4: ¿Cómo implementar un prototipo que aplique el modelo validado a nuevos relatos de estudiantes de la UNSAAC como apoyo a la revisión humana?

1.3. Objetivos

1.3.1. Objetivo general

Desarrollar un modelo de aprendizaje automático para la detección de acoso sexual en relatos de estudiantes de la UNSAAC, cuyo desempeño se evaluará mediante el macro F1 y la exhaustividad en relatos de prueba, frente a una línea base léxica.

1.3.2. Objetivos específicos

OE1: Construir un corpus anonimizado y anotado de relatos de estudiantes de la UNSAAC para entrenar y validar el modelo de aprendizaje automático, determinando el nivel de acuerdo entre anotadores.

OE2: Entrenar y seleccionar el modelo de aprendizaje automático con mejor desempeño en la detección de acoso sexual, con y sin tratamiento del desbalance de clases, sin fuga de información.

OE3: Validar el desempeño del modelo seleccionado en la detección de acoso sexual en relatos de estudiantes de la UNSAAC frente a una línea base de referencia, analizando sus errores.

OE4: Implementar un prototipo que aplique el modelo validado a nuevos relatos de estudiantes de la UNSAAC como apoyo a la revisión humana.

1.4. Justificación

1.4.1. Conveniencia

La investigación es conveniente porque responde a un vacío concreto de la UNSAAC: la universidad recibe muy pocas denuncias de hostigamiento sexual frente a lo que reportan sus estudiantes (Gutiérrez de Alarcón et al., 2022). Un modelo capaz de identificar relatos que describen acoso ayudaría a las oficinas de orientación y atención a organizar y priorizar la información que reciben, en línea con las obligaciones que la ley les impone (Congreso de la República del Perú, 2003; Ministerio de la Mujer y Poblaciones Vulnerables, 2019).

1.4.2. Relevancia

El acoso sexual afecta la dignidad, el bienestar y hasta la permanencia de los estudiantes en la universidad (Bondestam & Lundqvist, 2020). Contar con un modelo entrenado con relatos de la propia comunidad es un primer paso para que la institución

pueda apoyarse en herramientas tecnológicas al atender estos casos. Quienes participen lo harán de forma voluntaria, y sus relatos serán anonimizados antes de cualquier análisis.

1.4.3. Implicancias prácticas

Desde la Ingeniería Informática y de Sistemas, el trabajo resuelve un problema práctico: construir un clasificador confiable con textos sensibles, escasos y desbalanceados, y ponerlo a disposición de quien lo necesita mediante un prototipo de fácil uso. El código, el modelo y su documentación (Gebru et al., 2021; Mitchell et al., 2019) podrán reutilizarse en otros sistemas de la universidad que procesen información personal. El prototipo no reemplaza a quien revisa los casos; le da una segunda lectura y le muestra en qué palabras se apoyó la predicción.

1.4.4. Valor teórico

Los estudios previos analizaron temas en relatos de acoso (Karami et al., 2020), clasificaron tipos de acoso (Wijaya et al., 2022) o detectaron revelaciones y testimonios en redes sociales, tanto en neerlandés (Gorissen et al., 2023) como en español (Escobar Mercado et al., 2022). Ninguno trabajó con relatos de estudiantes universitarios aportados con consentimiento ni en una universidad peruana. Este trabajo aporta evidencia sobre qué tan bien aprende un modelo los criterios con los que se reconoce el acoso en un texto y en qué tipo de relatos se equivoca, lo que ayuda a acortar la distancia entre la definición social del fenómeno y su etiqueta computacional (Dutta et al., 2025).

1.4.5. Utilidad metodológica

La investigación deja un procedimiento completo para trabajar con textos sensibles: cómo recolectarlos con consentimiento, cómo anonimizarlos, cómo etiquetarlos con una guía y cómo evaluar un modelo sin que los datos de prueba se filtren en el entrenamiento (Kapoor & Narayanan, 2023). Este procedimiento puede servir a otros estudios que trabajen con relatos en español.

1.5. Delimitación de Estudio

El modelo trabajará con relatos escritos en español; los que estén escritos principalmente en quechua u otra lengua quedarán fuera de esta primera versión. Las etiquetas reflejarán el juicio de los anotadores sobre lo que el relato cuenta, sin verificar los hechos, y la participación voluntaria no permitirá estimar cuántos estudiantes viven acoso.

1.5.1. Delimitación espacial

El estudio se realizará en la Universidad Nacional de San Antonio Abad del Cusco, en la ciudad del Cusco, Perú, con estudiantes matriculados y mayores de edad.

1.5.2. Delimitación temporal

La investigación se ejecutará en doce meses, contados desde la aprobación del plan de tesis. Los relatos se recolectarán una sola vez, durante el periodo autorizado.

1.6. Hipótesis

1.6.1. Hipótesis general

El modelo de aprendizaje automático desarrollado detecta acoso sexual en relatos de estudiantes de la UNSAAC con un desempeño significativamente superior al de una línea base de referencia.

1.6.2. Hipótesis específicas

HE1: El corpus de relatos de estudiantes de la UNSAAC, construido con anonimización y doble anotación, alcanza un acuerdo entre anotadores al menos sustancial ($\kappa \geq 0{,}61$).

HE2: El tratamiento del desbalance de clases, aplicado al entrenar los modelos de aprendizaje automático candidatos, incrementa su exhaustividad en la detección de acoso sexual.

HE3: El modelo seleccionado, validado en los relatos de prueba, alcanza en la detección de acoso sexual una exhaustividad superior a la de la línea base léxica, incluso en relatos sin términos sexuales explícitos.

HE4: El prototipo implementado reproduce las predicciones del modelo validado sobre nuevos relatos de estudiantes de la UNSAAC y cumple los requisitos funcionales definidos.

1.6.3. Contraste de las hipótesis

Sea m^* el modelo seleccionado y *léx* la línea base léxica, que marca como acoso todo relato que contenga al menos una palabra de una lista de términos sexuales definida antes del entrenamiento. La hipótesis general se contrasta así:

$$H_0 : \ \text{Macro}F_1^{(m^*)} \leq \text{Macro}F_1^{(\text{léx})} \qquad H_1 : \ \text{Macro}F_1^{(m^*)} > \text{Macro}F_1^{(\text{léx})} \tag{1}$$

Se trabajará con un nivel de significancia $\alpha = 0{,}05$. Como todos los modelos se prueban con los mismos relatos, las comparaciones son pareadas: se usará la prueba de McNemar (Dietterich, 1998; McNemar, 1947) y se calcularán intervalos de confianza del 95 % por remuestreo *bootstrap* (Efron & Tibshirani, 1993). H_0 se rechaza si $p < 0{,}05$ y el límite inferior del intervalo de la diferencia es mayor que cero. Cuando haya varias comparaciones a la vez, los valores p se ajustarán con el método de Holm (1979). La Tabla 2 resume los criterios para cada hipótesis.

Tabla 2
Criterios de contraste de las hipótesis

Hipótesis	Indicador	Criterio de decisión
General	Diferencia de macro F1 entre m^* y la línea base léxica	McNemar e IC 95 % *bootstrap*; se rechaza H_0 si $p < 0{,}05$ y el límite inferior del IC es mayor que 0
HE1	Kappa de Cohen antes de resolver desacuerdos	Se acepta si $\kappa \geq 0{,}61$, nivel sustancial según Landis y Koch (1977)
HE2	Exhaustividad de la clase positiva con y sin tratamiento del desbalance	Se acepta si el límite inferior del IC 95 % de la diferencia es mayor que 0
HE3	Exhaustividad de m^* y de la línea base léxica, global y en relatos sin términos explícitos	McNemar sobre los relatos con acoso, con ajuste de Holm; $p < 0{,}05$
HE4	Coincidencia de predicciones entre prototipo y modelo; requisitos aprobados	100 % de coincidencia y 100 % de requisitos funcionales aprobados

Nota. IC: intervalo de confianza. Elaboración propia.

1.7. Variables

1.7.1. Identificación de variables

- **Variable independiente:** modelo de aprendizaje automático, definido por la forma de representar el texto, el algoritmo de clasificación y el tratamiento del desbalance de clases.
- **Variable dependiente:** detección de acoso sexual en relatos de estudiantes de la UNSAAC, medida por el desempeño del modelo en relatos de participantes que no se usaron para entrenarlo.
- **Variables de control:** calidad del corpus, particiones y semillas comunes, y reproducibilidad del procedimiento.

1.7.2. Operacionalización de variables

La Tabla 3 detalla las dimensiones, indicadores e instrumentos de cada variable. La matriz de consistencia está en el Anexo A.

Tabla 3
Matriz de operacionalización de variables

Variable	Dimensión	Indicador	Instrumento	Escala
VI: Modelo de aprendizaje automático	Representación	TF-IDF con n-gramas de palabras y caracteres; representación contextual de BETO	Registro de experimentos	Nominal
	Algoritmo	Regresión logística, SVM lineal, Naïve Bayes y BETO; líneas base léxica y mayoritaria	Registro de experimentos	Nominal
	Tratamiento del desbalance	Sin tratamiento, ponderación de clases y remuestreo	Registro de experimentos	Nominal
VD: Detección de acoso sexual	Desempeño global	Macro F1	Matriz de confusión	Razón [0, 1]
	Clase positiva	Precisión, exhaustividad y F1 de los relatos con acoso	Matriz de confusión e IC 95 %	Razón [0, 1]
	Errores	Cantidad y tipo de falsos positivos y falsos negativos	Ficha de análisis de errores	Razón / nominal
Control: calidad del corpus	Acuerdo entre anotadores	Kappa de Cohen y acuerdo porcentual	Ficha de anotación	Razón
	Cobertura	Tasa de exclusión y proporción de clases	Registro de exclusiones	Razón
Control: reproducibilidad	Reproducibilidad	Diferencia de métricas entre reejecuciones	Control de versiones	Razón

Nota. Elaboración propia.

1.8. Método

1.8.1. Tipo

Es una investigación aplicada de tipo tecnológico, porque usa conocimientos de aprendizaje automático y procesamiento del lenguaje natural para construir un modelo y un prototipo que atienden un problema concreto de la universidad. Tiene enfoque cuantitativo, ya que el desempeño de los modelos se mide con números y las hipótesis se contrastan con pruebas estadísticas (Hernández-Sampieri & Mendoza Torres, 2023). Su alcance es explicativo: el objetivo general pide desarrollar el modelo y comprobar que detecta el acoso mejor que una línea base, lo que exige establecer el efecto del algoritmo y del tratamiento del desbalance sobre el desempeño.

1.8.2. Diseño

El diseño es experimental, en la forma de un experimento computacional factorial con medidas repetidas. Se manipulan dos factores, el algoritmo y el tratamiento del desbalance, se mide el desempeño de cada combinación y se compara con dos líneas base que actúan como grupos de control (Hernández-Sampieri & Mendoza Torres, 2023). Los participantes se reparten al azar entre los conjuntos de desarrollo y prueba, y cada relato de prueba es clasificado por todas las configuraciones, así que cada relato funciona como su propio control. Con las personas no se interviene de ningún modo: solo se recogen sus relatos una vez.

Este diseño responde a la naturaleza del problema. Lo que se quiere saber es si un modelo detecta el acoso mejor que otro, y la forma más justa de averiguarlo es enfrentar a todos con los mismos relatos, sin que ninguno los haya visto al entrenar. Las medidas repetidas permiten usar pruebas pareadas como la de McNemar, recomendada para comparar clasificadores (Dietterich, 1998), y la separación por participante evita la fuga de información descrita por Kapoor y Narayanan (2023).

El esquema del diseño es el siguiente, y la Tabla 4 muestra los niveles de cada

factor:

$$R \rightarrow \begin{cases} X_0 \rightarrow O_0,\ X_1 \rightarrow O_1 & \text{(control: líneas base mayoritaria y léxica)} \\ X_{ij} \rightarrow O_{ij} & i \in \{2,3,4,5\},\ j \in \{0,1,2\} \end{cases} \tag{2}$$

donde R es la asignación aleatoria de participantes, X_{ij} la configuración formada por el algoritmo i y el tratamiento j, y O_{ij} las métricas obtenidas sobre los mismos relatos de prueba.

Tabla 4
Niveles de los factores del diseño experimental

Factor	**Niveles**	**Observación**
A: Algoritmo	A_0 línea base mayoritaria y A_1 línea base léxica (control); A_2 regresión logística, A_3 SVM lineal y A_4 Naïve Bayes con TF-IDF; A_5 BETO	BETO se entrena en un equipo local, sin enviar relatos a servicios externos
B: Tratamiento del desbalance	B_0 sin tratamiento (control); B_1 ponderación de clases; B_2 remuestreo dentro del entrenamiento	B_2 solo se aplica con TF-IDF
Configuraciones	2 controles, 9 combinaciones con TF-IDF y 2 con BETO: 13 configuraciones probadas con los mismos relatos	

Nota. Elaboración propia.

1.8.3. Objeto de estudio, población y muestra

El objeto de estudio es el corpus de relatos escritos en español sobre situaciones vividas en la UNSAAC: sobre esos textos se entrenan y se prueban los modelos. Los relatos provienen de una población formada por los estudiantes mayores de edad matriculados en la UNSAAC durante el periodo de recolección. El muestreo será no probabilístico, por participación voluntaria, procurando que participen estudiantes de distintas escuelas y semestres. Primero se hará un piloto con unos 40 relatos para probar el formulario, la anonimización y la guía de anotación; la muestra principal será de 400 a 600 relatos válidos, lo que permite reservar alrededor de 100 relatos para la prueba final y entrenar con el resto. Si una persona aporta más de un relato, todos irán al mismo conjunto, de desarrollo o de prueba.

No hace falta haber vivido acoso para participar. También se invitará a contar situaciones universitarias comunes, sin acoso, para que el modelo aprenda a distinguir ambos casos. Se recogen relatos propios en lugar de usar un conjunto público porque los disponibles en español son tuits o mensajes sobre otros fenómenos, no relatos universitarios (Escobar Mercado et al., 2022; Rodríguez-Sánchez et al., 2021). Se descartarán los relatos duplicados, los que cuenten experiencias de terceros sin autorización, los que contengan datos personales imposibles de retirar y los que no den información suficiente.

1.8.4. Técnicas e instrumentos de recolección de datos

Hay dos tipos de instrumentos. Para construir el corpus se usarán una ficha de consentimiento, un formulario de relato voluntario (Anexo C), una ficha de anonimización y una guía de anotación (Anexo B); la guía será revisada por al menos dos especialistas en acoso sexual y un especialista en metodología. Para medir el desempeño de los modelos no se usarán encuestas, sino instrumentos automáticos: *scripts* de evaluación que calculan las métricas a partir de las matrices de confusión, un registro de experimentos que guarda la configuración, las semillas y los resultados de cada ejecución, y los registros (*logs*) del prototipo para medir su tiempo de respuesta.

Dos anotadores capacitados etiquetarán cada relato por separado como *con acoso sexual*, *sin acoso sexual* o *información insuficiente*. Antes de resolver sus diferencias se medirá cuánto coinciden, con el acuerdo porcentual y el kappa de Cohen; luego un especialista resolverá los desacuerdos. Para entrenar el modelo solo se usarán los relatos con una etiqueta final clara.

1.8.5. Técnicas de procesamiento y análisis de datos

El procesamiento se programará en Python, con scikit-learn (Pedregosa et al., 2011) para los modelos con TF-IDF y la biblioteca Transformers (Wolf et al., 2020) para BETO; la elección de estas herramientas se justifica en el Capítulo 2. La vectorización y el remuestreo se ajustarán solo con los datos de entrenamiento de cada pliegue, y los relatos casi idénticos se agruparán antes de dividir el corpus, para que una misma experiencia

no aparezca a la vez en entrenamiento y prueba. Se registrarán las semillas, versiones, particiones y parámetros de cada experimento. Los modelos se validarán con validación cruzada agrupada de cinco pliegues y, al final, con una prueba única sobre los relatos reservados. Para las métricas principales se calcularán intervalos de confianza del 95 % mediante remuestreo por participante, y las comparaciones se harán con la prueba de McNemar (Ecuación 16) y el ajuste de Holm.

1.8.6. Entorno de pruebas

Todos los experimentos se ejecutarán en un equipo local, sin servicios en la nube. La Tabla 5 detalla sus características mínimas. Las versiones de cada biblioteca se fijarán en un archivo de dependencias al iniciar los experimentos, para que cualquiera pueda repetirlos.

Tabla 5
Entorno de pruebas

Componente	**Especificación**
Procesador	CPU de 8 núcleos o más
Memoria	16 GB de RAM
GPU	NVIDIA con al menos 8 GB de memoria y soporte CUDA, para el ajuste fino de BETO
Almacenamiento	Disco SSD con cifrado activado
Sistema operativo	Ubuntu 22.04 LTS
Lenguaje	Python 3.11
Aprendizaje automático	scikit-learn 1.5, imbalanced-learn 0.12, PyTorch 2.4 y Transformers 4.44
Explicabilidad	SHAP 0.46
Prototipo	FastAPI 0.115 (servidor) y React 18 (interfaz)
Modelo preentrenado	BETO, versión `bert-base-spanish-wwm-cased`

Nota. Elaboración propia.

1.8.7. Consideraciones éticas

No se recogerá ningún relato antes de contar con la aprobación del comité de ética y de la universidad. El consentimiento explicará para qué se usará el relato, quién tendrá

acceso, cuánto tiempo se guardará y cómo retirarse. Nadie estará obligado a participar ni sufrirá consecuencias académicas por no hacerlo, y la convocatoria no se hará a través de docentes que evalúen a los estudiantes. El formulario aclarará que no es un canal de denuncia e indicará a dónde acudir si se necesita ayuda.

No se pedirán nombres de las personas involucradas. Antes del entrenamiento, una revisión manual eliminará cualquier dato que permita identificar a alguien. Los archivos se guardarán cifrados y todo el procesamiento, incluido el entrenamiento de BETO, se hará en equipos locales, sin enviar los relatos a servicios en la nube ni a sistemas de inteligencia artificial generativa. El corpus no se publicará; el código se compartirá solo con datos de ejemplo. Las predicciones del modelo no se usarán para sancionar ni para identificar responsables.

1.8.8. Cronograma de actividades

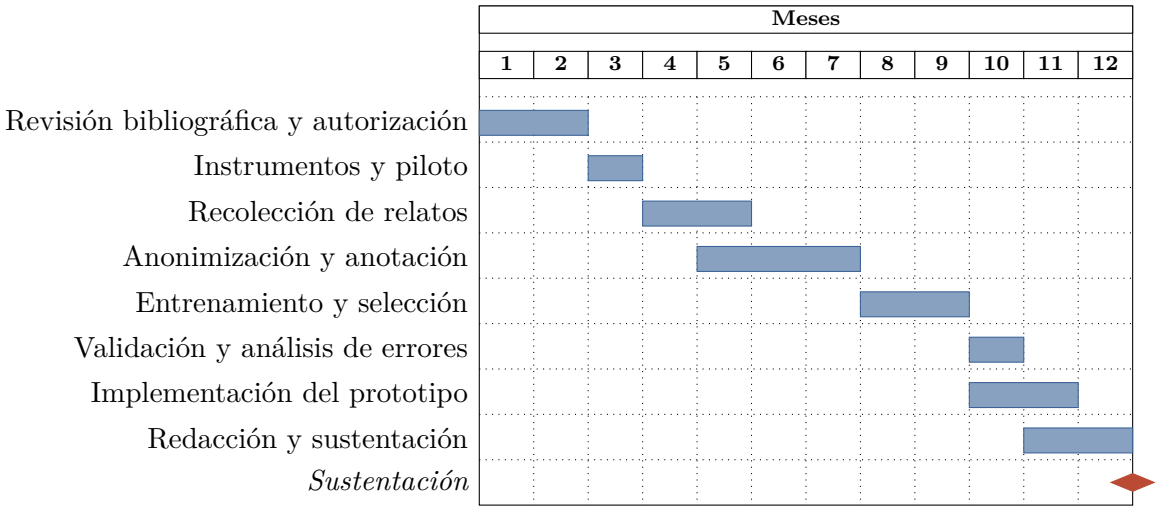
La Tabla 6 y la Figura 1 muestran la programación de las actividades.

Tabla 6
Cronograma de actividades

Actividad	**Meses**	**Producto**
Revisión bibliográfica y autorización ética	1 y 2	Protocolo aprobado
Elaboración de instrumentos y piloto	3	Instrumentos validados
Recolección de relatos	4 y 5	Relatos recibidos
Anonimización y anotación	5 a 7	Corpus anotado
Entrenamiento y selección del modelo	8 y 9	Modelo seleccionado
Validación final y análisis de errores	10	Resultados
Implementación del prototipo	10 y 11	Prototipo verificado
Redacción y sustentación	11 y 12	Informe final de tesis

Nota. Los meses se cuentan desde la aprobación del plan. Elaboración propia.

Figura 1
Diagrama de Gantt de la investigación



Nota. Elaboración propia.

1.9. Presupuesto

La Tabla 7 muestra el presupuesto en soles. La investigación se financiará con recursos propios. Se cuenta con una computadora personal, y el trabajo de la tesista no se incluye como costo.

Tabla 7
Presupuesto de la investigación

Concepto	**Detalle**	**Subtotal (S/)**
Internet y respaldo cifrado	12 meses a S/ 30	360
Revisión de especialistas y anotación	Honorarios	900
Uso de equipo con GPU para entrenar BETO	Equipo o laboratorio local	400
Difusión de la convocatoria	Afiches y materiales	120
Impresiones y trámites	Ejemplares y derechos	200
Subtotal		**1980**
Imprevistos	10 % del subtotal	198
Total		**2178**

Nota. Elaboración propia.

2. Marco Teórico

2.1. Antecedentes

Se revisaron estudios que usan técnicas computacionales para analizar o clasificar textos sobre acoso y violencia sexual, en inglés y en español, revisiones sobre cómo se mide este fenómeno y trabajos sobre acoso sexual en universidades. La Tabla 8 resume los más cercanos a esta investigación.

Tabla 8
Resumen de los antecedentes más cercanos

Autor y año	Objetivo	Método	Datos	Métricas	Resultados	Limitaciones
Gorissen et al. (2023)	Identificar revelaciones de victimización sexual en línea	Clasificación binaria supervisada	599 591 mensajes públicos en neerlandés	Kappa; revisión de falsos negativos	2927 revelaciones; $\kappa = 0{,}878$	Victimización sexual en general; detalles del modelo en material suplementario
Wijaya et al. (2022)	Clasificar el tipo de acoso	TF-IDF, Naïve Bayes, KNN y SMOTE	2053 relatos académicos en inglés	AUC, precisión, exhaustividad, F1	AUC de 0,95 con Naïve Bayes	Clasifica tipos, no presencia de acoso; SMOTE antes de separar la prueba
Karami et al. (2020)	Descubrir temas en experiencias de acoso académico	LDA y codificación cualitativa	2379 relatos en inglés	Peso de temas; kappa	41 temas agrupados en 5	No entrena un clasificador
Mohammadi et al. (2024)	Detectar sexismo con explicaciones	BERT, CNN y SHAP	14 000 publicaciones en inglés	Exactitud, precisión, exhaustividad, F1	F1 de 0,76	Sexismo, no acoso; métricas ponderadas
Escobar Mercado et al. (2022)	Analizar los testimonios de #Cuéntalo	Clasificación supervisada por frecuencia de palabras y LDA	52 411 tuits originales en español	No reportadas	32 % de mensajes con agresiones	Tuits breves; no reporta precisión del clasificador
Imbaquinga Guaña y Lara Anago (2025)	Detectar cibergrooming y cibersexting	MiniLM, SMOTE y LightGBM; prototipo web	Mensajes en español	Precisión, exhaustividad, F1 macro	F1 macro de 96,16 %	Mensajes dirigidos a menores, no relatos de acoso
Gutiérrez de Alarcón et al. (2022)	Medir la prevalencia del hostigamiento sexual	Encuesta transversal	151 estudiantes de la UNSAAC	Proporciones	77,5 % de prevalencia; menos del 1 % denunció	Muestra no probabilística; no analiza textos
Aguirre Soto et al. (2022)	Detectar ciberacoso en Twitter	Clasificación binaria con BERT	Publicaciones de Twitter	No reportadas en el texto	Gráficos del entrenamiento	Sin conjunto de prueba independiente

Nota. Elaboración propia a partir de los estudios citados.

2.1.1. Antecedentes internacionales

Antecedente 1

Gorissen, M., van den Berg, C. J. W., Ruiter, S., & Bijleveld, C. C. J. H. (2023). Sharing unwanted sexual experiences online: A cross-platform analysis of disclosures before, during and after the #MeToo movement. *Computers in Human Behavior, 144*, Artículo 107724. https://doi.org/10.1016/j.chb.2023.107724

Institución: Vrije Universiteit Amsterdam y Netherlands Institute for the Study of Crime and Law Enforcement, Países Bajos.

Conclusiones:

- Reunieron 599 591 mensajes públicos en neerlandés publicados entre 2017 y 2018 y plantearon la identificación de revelaciones de victimización sexual como una clasificación binaria supervisada, con un modelo para Twitter y otro para las demás plataformas.
- Etiquetaron a mano 100 000 mensajes para el entrenamiento. Un segundo anotador codificó 150 mensajes y el acuerdo alcanzó un kappa de 0,878. Al final identificaron 2927 revelaciones, el 80,4 % en Twitter.
- Los mensajes de Twitter fueron los más cortos y con menos información, incluso después de controlar la longitud del texto.

Comentario: Es el estudio más parecido a esta tesis en lo técnico, porque entrena un modelo que separa textos con y sin una experiencia personal de victimización sexual. También es útil su forma de etiquetar: los mensajes sin contexto suficiente o que hablaban de terceros se consideraron negativos. Sin embargo, trabaja con publicaciones públicas en neerlandés, tomadas sin consentimiento de sus autores, y su tema es la victimización sexual en general. De este estudio se toma el criterio de «información insuficiente» para la guía de anotación.

Antecedente 2

Wijaya, I. D., Putrada, A. G., & Oktaria, D. (2022). Overcoming data imbalance problems in sexual harassment classification with SMOTE. *International Journal on Information and Communication Technology, 8*(1), 20–29. https://doi.org/10.21108/ijoict.v8i1.622

Institución: Telkom University, Indonesia.

Conclusiones:

- Clasificaron 2053 relatos de una encuesta en línea en dos tipos de acoso: ambiente hostil (1842 relatos, 90 %) e intercambio condicionado (211 relatos, 10 %), usando TF-IDF, SMOTE, Naïve Bayes y KNN.
- Naïve Bayes superó a KNN, con un AUC de 0,95 frente a 0,92.
- Con SMOTE, la precisión de la clase minoritaria en Naïve Bayes subió de 74 % a 90 %.

Comentario: El estudio respalda el uso de clasificadores clásicos con TF-IDF y la importancia de tratar el desbalance de clases. Pero su evaluación deja una duda: el diagrama metodológico ubica SMOTE antes de dividir los datos en entrenamiento y prueba, lo que sugiere que el conjunto de prueba pudo incluir ejemplos sintéticos y que las métricas estarían sobrestimadas. En esta tesis, el remuestreo se hará siempre después de separar la prueba y solo con los datos de entrenamiento.

Antecedente 3

Karami, A., White, C. N., Ford, K., Swan, S., & Yildiz Spinel, M. (2020). Unwanted advances in higher education: Uncovering sexual harassment experiences in academia with text mining. *Information Processing & Management, 57*(2), Artículo 102167. https://doi.org/10.1016/j.ipm.2019.102167

Institución: University of South Carolina, Estados Unidos.

Conclusiones:

- Analizaron 2379 experiencias de acoso en el ámbito académico con frecuencias de palabras y LDA. De 45 temas, 41 fueron pertinentes y se agruparon en cinco: acoso

de género, discriminación sexual, atención sexual no deseada, coerción sexual y represalias.

- La atención sexual no deseada fue el grupo más grande, con 23 de los 41 temas.
- Un codificador externo revisó 11 temas y el acuerdo alcanzó un kappa de 0,80.

Comentario: Es el antecedente que trabaja con el tipo de texto más parecido al de esta tesis: relatos universitarios escritos libremente. Sus categorías sirven de referencia para la guía de anotación. A diferencia de esta tesis, no entrena un detector, porque todos sus textos ya eran experiencias de acoso.

Antecedente 4

Mohammadi, H., Giachanou, A., & Bagheri, A. (2024). A transparent pipeline for identifying sexism in social media: Combining explainability with model prediction. *Applied Sciences, 14*(19), Artículo 8620. https://doi.org/10.3390/app14198620

Institución: Utrecht University, Países Bajos.

Conclusiones:

- Combinaron versiones de BERT con una red convolucional y usaron SHAP para mostrar qué palabras pesan más cuando un texto se clasifica como sexista.
- Trabajaron con 14 000 publicaciones de Gab y Reddit del conjunto EDOS, de las cuales el 24 % eran sexistas.
- Su mejor modelo alcanzó una exactitud de 0,79, una exhaustividad de 0,79 y un F1 de 0,76, por encima de los modelos que lo componen por separado.

Comentario: Aporta dos ideas que esta tesis retoma: comparar varios modelos sobre los mismos datos y mostrar las palabras que explican cada predicción, algo que tendrá el prototipo. Hay que tener en cuenta que el sexismo no es lo mismo que el acoso sexual. Además, su exhaustividad coincide con su exactitud, lo que indica métricas ponderadas por clase; por eso su F1 no sirve como meta para esta investigación.

Antecedente 5

Salawu, S., He, Y., & Lumsden, J. (2020). Approaches to automated detection of cyberbullying: A survey. *IEEE Transactions on Affective Computing, 11*(1), 3–24. https://doi.org/10.1109/TAFFC.2017.2761757

Institución: Aston University, Reino Unido.

Conclusiones:

- Revisaron 46 estudios y agruparon los enfoques de detección en cuatro tipos: aprendizaje supervisado, basados en léxicos, basados en reglas y mixtos.
- La clasificación binaria fue la tarea más común (34 de 46 estudios), y SVM y Naïve Bayes los clasificadores más usados. Solo tres estudios recurrieron a expertos para etiquetar los datos.
- Los principales retos fueron la falta de datos etiquetados y la dificultad de reconocer el acoso sin contexto.

Comentario: Este trabajo orienta la construcción del corpus, la participación de especialistas en la guía de anotación y el análisis de errores. Su tema es el ciberacoso en general y solo revisó estudios en inglés.

Antecedente 6

Dutta, A., Banducci, S., & Camargo, C. Q. (2025). Divided by discipline? A systematic literature review on the quantification of online sexism and misogyny using a semi-automated approach. *Scientometrics, 130*(9), 4915–4971. https://doi.org/10.1007/s11192-025-05410-2

Institución: University of Exeter, Reino Unido.

Conclusiones:

- Hicieron una revisión sistemática guiada por PRISMA que partió de 1745 registros e incluyó 48 estudios publicados entre 2012 y 2022.

- Encontraron que las ciencias sociales y las ciencias de la computación definen y miden el sexismo de formas distintas.
- De los conjuntos de datos revisados, 36 estaban en inglés y solo 7 en español.

Comentario: Muestra por qué hace falta una definición clara y una guía de anotación antes de entrenar un modelo, y confirma que hay pocos recursos en español.

Antecedente 7

Bondestam, F., & Lundqvist, M. (2020). Sexual harassment in higher education – a systematic review. *European Journal of Higher Education, 10*(4), 397–419. https://doi.org/10.1080/21568235.2020.1729833

Institución: University of Gothenburg, Suecia.

Conclusiones:

- Revisaron la investigación publicada entre 1966 y 2017, partiendo de 5259 registros.
- En promedio, una de cada cuatro estudiantes mujeres reporta acoso sexual. Las jerarquías, la precariedad laboral, la normalización de la violencia y la cultura del silencio aparecen como factores que lo facilitan, junto con un subregistro constante.
- Casi no hay evidencia sobre el efecto real de las medidas de prevención.

Comentario: Sustenta la relevancia del problema en las universidades y, sobre todo, el subregistro. No trabaja con algoritmos.

Antecedente 8

Ríos-Albert, E., Cerdán-Torregrosa, A., Espinar-Ruiz, E., Jaskulska, S., Jankowiak, B., Del Piccolo, L., Donisi, V., Dal Maso, F., Avery, S., Sousa, M., Silva, E., Neves, S., Stifter, V., Wallner, M., & Vives-Cases, C. (2026). «Sexual harassment definitely involves a hierarchical transgression»: Key informants' discourses on sexual harassment in European universities. *PLOS ONE, 21*(8), Artículo e0355556. https://doi.org/10.1371/journal.pone.0355556

Institución: Universidad de Alicante (España), junto con otras cinco universidades europeas.

Conclusiones:

- Realizaron 90 entrevistas a representantes estudiantiles, personal y unidades de igualdad de seis universidades europeas.
- Los entrevistados definieron el acoso sexual con cuatro elementos: transgresión de límites, ausencia de consentimiento, desequilibrio de poder e impacto en el bienestar. También describieron «zonas grises» de conductas sutiles que suelen normalizarse.
- Aunque predominó la idea de un agresor con más jerarquía, también se mencionó el acoso entre pares.

Comentario: Sus cuatro elementos se usan como referencia en la guía de anotación. Como también documenta acoso entre pares, la guía no exigirá que el agresor tenga más jerarquía para etiquetar un relato como acoso.

Antecedente 9

Bull, A., & Bradley, A. (2026). Who is experiencing faculty/staff-student sexual misconduct in UK higher education? *Journal of Gender-Based Violence*. Publicación anticipada en línea. https://doi.org/10.1332/23986808Y2025D000000120

Institución: University of York y University of Portsmouth, Reino Unido.

Conclusiones:

- Analizaron una encuesta a 1768 estudiantes del Reino Unido sobre conductas sexuales inapropiadas del personal universitario.
- Adaptaron el SEQ para no preguntar si la persona rechazó la conducta, porque una relación de poder puede impedir que alguien se niegue.
- Las mujeres y algunos grupos de estudiantes vivieron más incidentes que el resto.

Comentario: Respalda una regla importante de la guía de anotación: que la persona no se haya negado no significa que haya consentido.

Antecedente 10

Escobar Mercado, M., Gil, E., & Calvo López, C. (2022). Análisis de la dinámica, la estructura y el contenido de los mensajes de Twitter: Violencia sexual en #Cuéntalo. *EMPIRIA. Revista de Metodología de Ciencias Sociales*, (53), 89–110. https://doi.org/10.5944/empiria.53.2022.32614

Institución: Universidad de Salamanca, España.

Conclusiones:

- Analizaron los mensajes publicados en Twitter con la etiqueta #Cuéntalo entre el 26 y el 28 de abril de 2018, tras la sentencia del caso «La Manada»: 491 258 intervenciones, de las cuales 52 411 fueron tuits originales, en su mayoría en español.
- Codificaron a mano una muestra de unos 10 000 mensajes según contuvieran o no agresiones sexuales, entrenaron con ella un clasificador supervisado basado en la frecuencia de palabras y lo aplicaron al resto del corpus. El 32 % de los mensajes describía agresiones, el 56 % no y el 12 % quedó sin definir.
- Con LDA encontraron que los temas más frecuentes eran el miedo a volver sola a casa y situaciones vividas en la escuela.

Comentario: Es el antecedente en español más cercano a esta tesis, porque separa automáticamente testimonios con y sin agresiones sexuales. Demuestra que la tarea es posible en nuestro idioma. Sin embargo, trabaja con tuits breves y públicos, no informa la precisión de su clasificador y su objetivo es describir un fenómeno social, no construir un modelo validado. Tampoco se ocupa del ámbito universitario.

Antecedente 11

Imbaquinga Guaña, J. R., & Lara Anago, N. A. (2025). *Modelo para la detección y prevención de cibergrooming y cibersexting utilizando algoritmos de procesamiento de lenguaje natural y técnicas de clasificación en aprendizaje automático* [Tesis de grado, Universidad de las Fuerzas Armadas ESPE]. Repositorio Institucional ESPE. https://repositorio.espe.edu.ec/handle/21000/61636

Institución: Universidad de las Fuerzas Armadas ESPE, Ecuador.

Conclusiones:

- Desarrollaron un modelo para detectar mensajes de cibergrooming y cibersexting dirigidos a niños y adolescentes.
- Representaron los mensajes con all-MiniLM-L6-v2, una versión reducida de BERT, equilibraron las clases con SMOTE y clasificaron con LightGBM. Obtuvieron una precisión de 97,24 %, una exhaustividad macro de 97,09 % y un F1 macro de 96,16 %.
- Integraron el modelo en un prototipo con una API en Flask y una interfaz en React, que asigna niveles de alerta según la probabilidad.

Comentario: Es un antecedente latinoamericano de una carrera de software con una propuesta muy parecida a la de esta tesis: un modelo de lenguaje, un clasificador y un prototipo web. La diferencia está en el fenómeno y en los datos: trata mensajes de acoso hacia menores, no relatos de estudiantes universitarios. Además, como aplica SMOTE, conviene comprobar que el remuestreo se haga solo con los datos de entrenamiento, cuidado que esta tesis incorpora.

Antecedente 12

Cumba Armijos, P. D. (2018). *Predicción de ataques de cyber bullying mediante técnicas de aprendizaje profundo apoyándose en un corpus de entrenamiento para la clasificación de texto en español* [Tesis de maestría, Universidad Internacional SEK]. Repositorio Digital UISEK. https://repositorio.uisek.edu.ec/handle/123456789/3224

Institución: Universidad Internacional SEK, Ecuador.

Conclusiones:

- Construyó un corpus de tuits en español etiquetados como acoso o no acoso, a partir de listas de palabras clave.
- Entrenó una red neuronal convolucional con representaciones de palabras (*word embeddings*) y la validó con validación cruzada.

- Concluyó que el modelo es adecuado para predecir ciberacoso en textos en español.

Comentario: Muestra que en la región ya se entrenan modelos para detectar acoso en español. Su punto débil es el etiquetado: al usar palabras clave para asignar las clases, el modelo aprende esas mismas palabras. Esta tesis evita ese problema etiquetando cada relato con una guía y comparando el modelo con una línea base léxica.

2.1.2. Antecedentes nacionales

Antecedente 13

Gutiérrez de Alarcón, R. D., Cuadra Moreno, M. L., Solano Coello, M. E., Paz Muro, E. S., Tapia Sánchez, C. D., Gutiérrez Alarcón, H. R., & Valencia Blanco, D. S. (2022). Prevalencia, reacciones y efectos del hostigamiento sexual en dos universidades públicas del Perú. *Revista de Investigación Estadística, 4*(1), 36–46. https://revistas.unitru.edu.pe/index.php/REDIES/article/view/4382

Institución: Universidad Nacional de Trujillo y Universidad Nacional de San Antonio Abad del Cusco, Perú.

Conclusiones:

- Con una encuesta aplicada en 2019, compararon la Universidad Nacional de Trujillo (2297 estudiantes) y la UNSAAC (151 estudiantes).
- En la UNSAAC, el 77,5 % reportó al menos una manifestación de hostigamiento sexual. Las más frecuentes fueron comentarios o chistes de tono sexual, preguntas sobre la vida sexual y silbidos o exclamaciones. El 17,2 % se identificó como víctima de hostigamiento virtual.
- Solo una de las 117 personas afectadas en la UNSAAC denunció el hecho. Los estudiantes fueron señalados como autores en el 72,6 % de los casos y los docentes en el 16,8 %.

Comentario: Es el antecedente más cercano al ámbito de esta tesis y muestra, con datos de la propia UNSAAC, cuán pocas experiencias llegan a denunciarse. También muestra

que buena parte de los casos ocurre entre estudiantes. La muestra es pequeña y el estudio no analiza el lenguaje de los relatos.

Antecedente 14

Aguirre Soto, J., Ávila Gonzales, H., & Bravo Saines, V. (2022). Uso de una herramienta de NLP aplicada a la detección del ciberacoso en Twitter. *Innovación y Software, 3*(2), 81–90. https://n2t.net/ark:/42411/s9/a65

Institución: Universidad La Salle, Arequipa, Perú.

Conclusiones:

- Propusieron clasificar publicaciones de Twitter como ciberacoso o contenido neutral con un modelo BERT.
- Usaron un etiquetado con cuatro niveles de confianza que luego agruparon en dos clases.
- Presentaron los resultados del entrenamiento principalmente con gráficos.

Comentario: Es un antecedente peruano de Ingeniería de Sistemas que muestra interés local por aplicar procesamiento del lenguaje al acoso. Se diferencia de esta tesis en que trata ciberacoso en Twitter y no describe un conjunto de prueba independiente ni métricas por clase.

2.1.3. Análisis comparativo de los antecedentes

Leídos en conjunto, los antecedentes muestran un camino claro. Los primeros trabajos analizaron relatos de acoso para entender el fenómeno, como Karami et al. (2020), que descubrieron temas en experiencias académicas sin clasificar textos. Después vinieron los clasificadores: Wijaya et al. (2022) separaron tipos de acoso con Naïve Bayes y Gorissen et al. (2023) distinguieron mensajes con y sin una revelación de victimización sexual. Más recientemente, los modelos *transformers* y las técnicas de explicabilidad se volvieron la referencia (Mohammadi et al., 2024).

En español el panorama es parecido, aunque con menos trabajos. Escobar Mercado et al. (2022) clasificaron testimonios de #Cuéntalo; Cumba Armijos (2018) y Aguirre Soto et al. (2022) detectaron ciberacoso en tuits; y Imbaquinga Guaña y Lara Anago (2025) integraron un modelo en un prototipo web para detectar cibergrooming. Estos estudios confirman que la tarea es posible en nuestro idioma y que tiene sentido llevar el modelo a una herramienta concreta, que es justamente lo que propone esta tesis.

La comparación también deja ver tres límites comunes. Primero, casi todos trabajan con publicaciones de redes sociales o con mensajes, que son breves y públicos; ninguno usa relatos de estudiantes universitarios aportados con consentimiento. Segundo, varios no informan bien cómo evaluaron sus modelos: Escobar Mercado et al. (2022) y Aguirre Soto et al. (2022) no reportan métricas por clase, y Wijaya et al. (2022) parecen haber aplicado SMOTE antes de separar la prueba. Tercero, en el Perú la evidencia sobre acoso en universidades viene de encuestas (Gutiérrez de Alarcón et al., 2022), que miden cuánto ocurre pero no analizan cómo se cuenta. Esta tesis toma lo que funcionó en esos trabajos, como los clasificadores clásicos como punto de partida, BETO para el español y SHAP para explicar, y lo aplica a relatos universitarios con una evaluación que evita esos problemas.

2.2. Bases Teóricas

2.2.1. Acoso sexual y hostigamiento sexual

En el Perú, la Ley N.º 27942 y su reglamento, aprobado por el Decreto Supremo N.º 014-2019-MIMP, regulan el hostigamiento sexual en las instituciones educativas, incluidas las universidades, y les asignan deberes de prevención, atención y sanción (Congreso de la República del Perú, 2003; Ministerio de la Mujer y Poblaciones Vulnerables, 2019). En esta tesis se usa el término *acoso sexual*, más común en la literatura internacional, como equivalente del hostigamiento sexual que describe la norma.

Para etiquetar los relatos, se considera que uno describe acoso sexual cuando cuenta, de forma explícita o clara por el contexto, conductas de naturaleza sexual no deseadas,

presiones o condicionamientos sexuales, o expresiones sexualizadas que afectan la dignidad de la persona. Sexismo, misoginia, violencia sexual y acoso sexual están relacionados, pero no son lo mismo (Bull & Bradley, 2026; Dutta et al., 2025). La guía de anotación toma los cuatro elementos que identificó Ríos-Albert et al. (2026): transgresión de límites, falta de consentimiento, desequilibrio de poder e impacto en el bienestar.

Que una persona no se haya negado de forma verbal no se interpreta como consentimiento, porque una relación de poder puede impedir esa respuesta (Bull & Bradley, 2026). Tampoco se suponen hechos que el relato no cuenta: si la situación es ambigua, se etiqueta como información insuficiente (Anexo B).

2.2.2. Relatos y mensajes

Un relato cuenta una experiencia y suele incluir cuándo pasó, qué consecuencias tuvo o por qué se vivió de cierta forma. Un mensaje, en cambio, puede ser una broma, una cita o parte de una conversación más larga. Por eso, un modelo entrenado con relatos no necesariamente funcionará con mensajes de chat. Gorissen et al. (2023) encontraron que el medio cambia el contenido: las revelaciones en Twitter eran más cortas y daban menos información que las publicadas en blogs.

2.2.3. Desarrollo de modelos con CRISP-DM

Desarrollar un modelo de aprendizaje automático no se reduce a entrenarlo. CRISP-DM organiza ese proceso en seis etapas: comprensión del problema, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue (Chapman et al., 2000). Las etapas no son rígidas: si la evaluación muestra un problema, se vuelve a una etapa anterior. En esta tesis, las seis etapas se agrupan en las cuatro etapas de trabajo del Capítulo 3, una por cada objetivo específico.

2.2.4. Representación de los textos

Un algoritmo no puede trabajar directamente con palabras; primero hay que convertir cada relato en un vector de números. La representación TF-IDF da a cada término

un peso que crece cuando aparece mucho en un relato y se reduce cuando aparece en casi todos:

$$\mathrm{tfidf}(t, d) = \mathrm{tf}(t, d) \cdot \log \frac{N}{\mathrm{df}(t)} \tag{3}$$

donde $\mathrm{tf}(t, d)$ es la frecuencia del término t en el relato d, N el número de relatos y $\mathrm{df}(t)$ el número de relatos que contienen el término. Además de palabras sueltas se usan n-gramas, es decir, secuencias de dos o más palabras o de caracteres, que capturan expresiones como «me tocó» y variaciones de escritura. Así, cada relato queda representado por un vector $\mathbf{x} \in \mathbb{R}^m$, donde m es el tamaño del vocabulario.

2.2.5. Clasificadores supervisados

En el aprendizaje supervisado se dispone de n relatos etiquetados $\{(\mathbf{x}_i, y_i)\}_{i=1}^{n}$, con $y_i = 1$ si el relato describe acoso y $y_i = 0$ si no. El objetivo es aprender una función que prediga y para relatos nuevos (Hastie et al., 2009). Esta tesis compara tres clasificadores muy usados con textos (Salawu et al., 2020).

Regresión logística

La regresión logística combina linealmente los pesos de las palabras y transforma el resultado en una probabilidad mediante la función sigmoide:

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^\top \mathbf{x} + b)}} \tag{4}$$

Los pesos $\mathbf{w}$ y el sesgo b se ajustan minimizando la entropía cruzada, a la que se suma una penalización $\lambda\|\mathbf{w}\|^2$ para evitar el sobreajuste:

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{n} \sum_{i=1}^{n} \Big[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \Big] + \lambda \|\mathbf{w}\|^2 \tag{5}$$

Su ventaja es que cada peso indica cuánto empuja una palabra hacia la clase de acoso, lo que facilita interpretar el modelo.

Máquina de vectores de soporte lineal

La SVM busca el hiperplano que separa las dos clases con el mayor margen posible (Cortes & Vapnik, 1995). Con etiquetas $y_i \in \{-1, +1\}$, el entrenamiento resuelve:

$$\min_{\mathbf{w},b} \ \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{n} \max\left(0,\ 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b)\right) \tag{6}$$

El primer término amplía el margen y el segundo, llamado pérdida *hinge*, penaliza los relatos que quedan del lado equivocado o demasiado cerca de la frontera. El parámetro C regula el equilibrio entre ambos. Las SVM lineales funcionan bien con vectores de muchas dimensiones y pocos ejemplos, como ocurre con TF-IDF.

Naïve Bayes multinomial

Naïve Bayes aplica el teorema de Bayes suponiendo que las palabras son independientes entre sí dentro de cada clase (McCallum & Nigam, 1998). La clase elegida es la de mayor probabilidad:

$$\hat{c} = \arg\max_{c \in \{0,1\}} \ \log P(c) + \sum_{t \in d} \mathrm{tf}(t,d)\, \log P(t \mid c), \qquad P(t \mid c) = \frac{N_{tc} + \alpha}{N_c + \alpha\,|V|} \tag{7}$$

donde N_{tc} es el número de veces que aparece el término t en los relatos de la clase c, N_c el total de términos de esa clase, $|V|$ el tamaño del vocabulario y α el suavizado que evita probabilidades nulas. Aunque su supuesto de independencia es poco realista, suele dar buenos resultados con pocos datos (Wijaya et al., 2022).

2.2.6. Modelos basados en *transformers*

Los modelos anteriores tratan cada palabra por separado. Un *transformer*, en cambio, representa cada palabra según las que la rodean, gracias al mecanismo de atención (Vaswani et al., 2017):

$$\text{Atención}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \tag{8}$$

donde Q, K y V son proyecciones de las palabras del relato y d_k su dimensión. Cada palabra calcula cuánta atención debe prestar a las demás, de modo que «me tocó» se representa distinto en «me tocó exponer» y en «me tocó la pierna».

BERT apila varias capas de atención y se preentrena con grandes volúmenes de texto (Devlin et al., 2019). Para clasificar, se toma la representación del token especial `[CLS]`, $\mathbf{h}_{\text{CLS}}$, y se le añade una capa de salida:

$$\hat{\mathbf{p}} = \text{softmax}(W\,\mathbf{h}_{\text{CLS}} + \mathbf{b}) \tag{9}$$

Todo el modelo se ajusta luego con los relatos etiquetados minimizando la entropía cruzada, proceso llamado *fine-tuning*. BETO es una versión de BERT preentrenada solo con textos en español, que superó a los modelos multilingües en la mayoría de tareas evaluadas (Cañete et al., 2020). En español también existen recursos para tareas cercanas, como el conjunto MeTwo de expresiones sexistas en Twitter (Rodríguez-Sánchez et al., 2020) y la tarea compartida EXIST 2021 (Rodríguez-Sánchez et al., 2021).

2.2.7. Líneas base

Una línea base es un modelo sencillo que sirve de punto de comparación. La línea base mayoritaria asigna a todos los relatos la clase más frecuente y marca el mínimo que cualquier modelo debería superar. La línea base léxica usa una lista $\mathcal{L}$ de términos sexuales definida antes del entrenamiento:

$$\hat{y}_{\text{léx}}(d) = \begin{cases} 1 & \text{si existe } t \in \mathcal{L} \text{ tal que } t \in d \\ 0 & \text{en otro caso} \end{cases} \tag{10}$$

Esta regla explica por qué se espera que el modelo la supere, que es lo que plantea la hipótesis. Si un relato describe acoso sin usar ningún término de la lista, por ejemplo «el profesor me dijo que si salía con él aprobaba», la regla siempre falla, mientras que un modelo entrenado puede aprender la relación entre «profesor», «salir» y «aprobar». Del mismo modo, la regla marca como acoso cualquier relato que mencione un término

sexual aunque no describa acoso, y el modelo puede aprender a distinguir esos casos por el contexto.

2.2.8. Desbalance de clases y fuga de información

Hay desbalance de clases cuando una clase tiene muchos más ejemplos que la otra. Un modelo puede acertar casi siempre prediciendo la clase mayoritaria y aun así no detectar ningún caso de acoso. Hay dos formas de corregirlo. La primera es ponderar las clases, dando más peso a los errores en la clase minoritaria:

$$w_c = \frac{n}{K \cdot n_c} \tag{11}$$

donde n es el número de relatos de entrenamiento, $K = 2$ el número de clases y n_c los relatos de la clase c. La segunda es SMOTE, que crea ejemplos sintéticos de la clase minoritaria interpolando entre un ejemplo $\mathbf{x}_i$ y uno de sus vecinos más cercanos $\mathbf{x}_{nn}$ (Chawla et al., 2002):

$$\mathbf{x}_{\text{nuevo}} = \mathbf{x}_i + \lambda\,(\mathbf{x}_{nn} - \mathbf{x}_i), \qquad \lambda \sim U(0,1) \tag{12}$$

Los ejemplos sintéticos no son relatos reales, así que nunca deben llegar al conjunto de prueba.

La fuga de información ocurre cuando datos que deberían reservarse para la evaluación terminan influyendo en el entrenamiento, y hace que el modelo parezca mejor de lo que es. Kapoor y Narayanan (2023) la encontraron en 294 estudios de 17 disciplinas. Se evita separando primero a los participantes y ajustando la vectorización y el remuestreo solo con los datos de entrenamiento de cada pliegue. En la validación cruzada agrupada, los relatos se reparten en k pliegues de modo que todos los de un mismo participante queden en el mismo pliegue. Documentar el corpus con una hoja de datos (Gebru et al., 2021) y el modelo con una ficha técnica (Mitchell et al., 2019) permite que otros revisen cómo se obtuvieron los resultados.

2.2.9. Métricas de evaluación

La precisión indica qué proporción de los relatos que el modelo marcó como acoso realmente lo eran; la exhaustividad, qué proporción de los relatos con acoso logró encontrar; y F1 combina ambas:

$$P = \frac{\mathrm{VP}}{\mathrm{VP} + \mathrm{FP}} \qquad R = \frac{\mathrm{VP}}{\mathrm{VP} + \mathrm{FN}} \qquad F_1 = 2 \cdot \frac{P \cdot R}{P + R} \tag{13}$$

donde VP son los verdaderos positivos, FP los falsos positivos y FN los falsos negativos, que se obtienen de la matriz de confusión. El macro F1 promedia el F1 de las dos clases con el mismo peso, así que no se infla cuando una clase es mucho más numerosa:

$$\mathrm{Macro}\, F_1 = \frac{F_1^{(0)} + F_1^{(1)}}{2} \tag{14}$$

Para medir cuánto coinciden los anotadores se usa el coeficiente kappa de Cohen, donde p_o es el acuerdo observado y p_e el acuerdo esperado por azar. Un valor de 0,61 o más se considera un acuerdo sustancial (Landis & Koch, 1977):

$$\kappa = \frac{p_o - p_e}{1 - p_e} \tag{15}$$

2.2.10. Pruebas estadísticas para comparar modelos

Como todos los modelos se prueban con los mismos relatos, sus resultados están pareados. La prueba de McNemar compara dos modelos fijándose solo en los relatos en que discrepan (McNemar, 1947). Si n_{01} es el número de relatos que el modelo A clasifica mal y el B bien, y n_{10} el caso contrario, el estadístico es:

$$\chi^2 = \frac{(|n_{01} - n_{10}| - 1)^2}{n_{01} + n_{10}} \tag{16}$$

que sigue una distribución χ^2 con un grado de libertad. Dietterich (1998) la recomienda para comparar clasificadores entrenados una sola vez, porque controla bien el error de tipo I.

Para estimar la incertidumbre de una métrica se usa el remuestreo *bootstrap* (Efron & Tibshirani, 1993): se generan B muestras con reemplazo de los relatos de prueba, se calcula la métrica en cada una y el intervalo de confianza al 95 % queda definido por los percentiles 2,5 y 97,5 de esos B valores. En esta tesis el remuestreo se hace por participante, para respetar que los relatos de una misma persona no son independientes. Cuando se hacen varias comparaciones a la vez, el método de Holm (1979) ordena los m valores p de menor a mayor y rechaza la hipótesis k-ésima solo si $p_{(k)} \leq \alpha/(m-k+1)$.

2.2.11. Explicabilidad

SHAP explica una predicción repartiéndola entre las características del texto. El valor de Shapley de la característica i es su aporte promedio a la predicción, considerando todas las combinaciones posibles de las demás (Lundberg & Lee, 2017):

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!\,(|F|-|S|-1)!}{|F|!} \Big[f(S \cup \{i\}) - f(S) \Big] \tag{17}$$

donde F es el conjunto de características y $f(S)$ la predicción usando solo las de S. La suma de todos los ϕ_i más el valor base da exactamente la predicción del modelo. Aplicado a textos, permite ver qué palabras empujaron al modelo a clasificar un relato como acoso y cuáles lo alejaron de esa decisión (Mohammadi et al., 2024). Estas explicaciones ayudan a quien revisa el caso a entender la predicción, pero no prueban que los hechos hayan ocurrido.

2.2.12. Arquitectura cliente-servidor para el prototipo

El prototipo sigue una arquitectura cliente-servidor. El servidor carga el modelo y lo expone mediante una interfaz de programación de aplicaciones (API) de estilo REST, en la que cada operación es una petición independiente que no guarda estado entre llamadas (Fielding, 2000). El cliente es una aplicación web que envía el relato, recibe la predicción y la muestra. Separar ambas partes permite cambiar el modelo sin tocar la interfaz y, como ambas funcionan en el mismo equipo, ningún relato sale de él.

2.3. Tecnologías y Entornos de Desarrollo

Las herramientas se eligieron por tres razones técnicas: que permitan ejecutar todo en un equipo local, que incluyan mecanismos para evitar la fuga de información y que su rendimiento sea suficiente para un corpus de cientos de relatos. La Tabla 9 resume la elección.

Tabla 9
Tecnologías seleccionadas y criterio técnico de elección

Tecnología	**Uso en la tesis**	**Criterio técnico**
Python	Lenguaje base	Concentra las bibliotecas de aprendizaje automático y procesamiento del lenguaje, y permite reproducir todo el proceso con un archivo de dependencias
scikit-learn	TF-IDF, clasificadores clásicos y validación cruzada	Sus *pipelines* encadenan vectorización, remuestreo y modelo, y se ajustan solo con los datos de entrenamiento de cada pliegue (Pedregosa et al., 2011)
PyTorch y Transformers	Ajuste fino de BETO	Dan acceso a modelos preentrenados en español y permiten entrenar en GPU local (Paszke et al., 2019; Wolf et al., 2020)
SHAP	Explicación de predicciones	Implementa los valores de Shapley para modelos lineales y *transformers* (Lundberg & Lee, 2017)
FastAPI	Servidor del prototipo	Expone el modelo como API REST con validación automática de los datos de entrada y atención asíncrona de peticiones, con baja latencia
React	Interfaz del prototipo	Construye la interfaz con componentes reutilizables que se actualizan sin recargar la página

Nota. Elaboración propia.

2.3.1. Bibliotecas de aprendizaje automático

scikit-learn reúne en una misma interfaz la vectorización, los clasificadores y las herramientas de validación (Pedregosa et al., 2011). Su característica más importante para esta tesis es el *pipeline*: un objeto que encadena todos los pasos y que, dentro de la validación cruzada, se ajusta de nuevo en cada pliegue usando solo sus datos de entrenamiento. Así se evita, por diseño, que el vocabulario de TF-IDF o los ejemplos de SMOTE se construyan con relatos de validación. Para BETO se usa PyTorch, que calcula

los gradientes de forma automática y aprovecha la GPU (Paszke et al., 2019), junto con la biblioteca Transformers, que carga el modelo preentrenado y su tokenizador con una interfaz común (Wolf et al., 2020).

2.3.2. Tecnologías del prototipo

El servidor se implementa con FastAPI, un marco de Python para construir APIs REST. Valida automáticamente que cada petición tenga el formato esperado, atiende peticiones de forma asíncrona y genera la documentación de la API. Como está escrito en Python, carga el mismo modelo entrenado sin necesidad de convertirlo. La interfaz se construye con React, una biblioteca de JavaScript que organiza la página en componentes, como el campo del relato, el resultado y la lista de palabras influyentes, que se actualizan cuando llega una respuesta del servidor.

3. Desarrollo de la Propuesta

3.1. Metodología de Desarrollo

El modelo se desarrollará siguiendo CRISP-DM (Chapman et al., 2000). Como se trabaja con relatos sensibles, a sus etapas se les añaden la autorización ética, la anotación y la documentación. Para que el trabajo responda directamente a los objetivos, las seis etapas de CRISP-DM se agrupan en cuatro etapas de desarrollo, una por cada objetivo específico (Tabla 10).

Tabla 10
Relación entre objetivos específicos, etapas de desarrollo y CRISP-DM

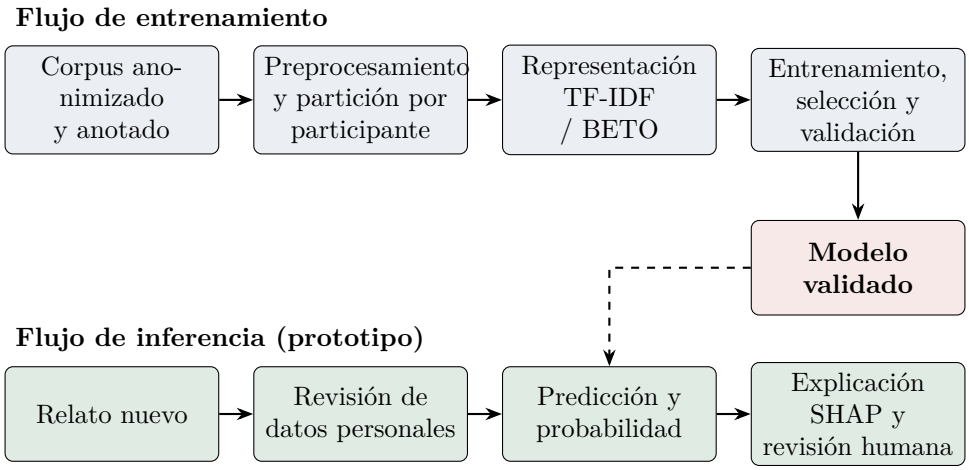
Objetivo	**Etapa de desarrollo**	**Etapas de CRISP-DM**	**Producto**
OE1	Etapa 1: Construcción del corpus	Comprensión del problema, comprensión y preparación de los datos	Corpus anonimizado y anotado, con su kappa y su hoja de datos
OE2	Etapa 2: Entrenamiento y selección del modelo	Preparación de los datos y modelado	Modelo seleccionado y registro de experimentos
OE3	Etapa 3: Validación del modelo	Evaluación	Métricas en la prueba, contraste de hipótesis y análisis de errores
OE4	Etapa 4: Implementación del prototipo	Despliegue	Prototipo verificado y ficha técnica del modelo

Nota. Adaptado de Chapman et al. (2000).

3.2. Arquitectura de la Solución

La solución tiene dos flujos, que se muestran en la Figura 2. En el flujo de entrenamiento, el corpus anotado se convierte en un modelo validado. En el flujo de inferencia, el prototipo usa ese modelo para analizar un relato nuevo.

Figura 2
Arquitectura de la solución

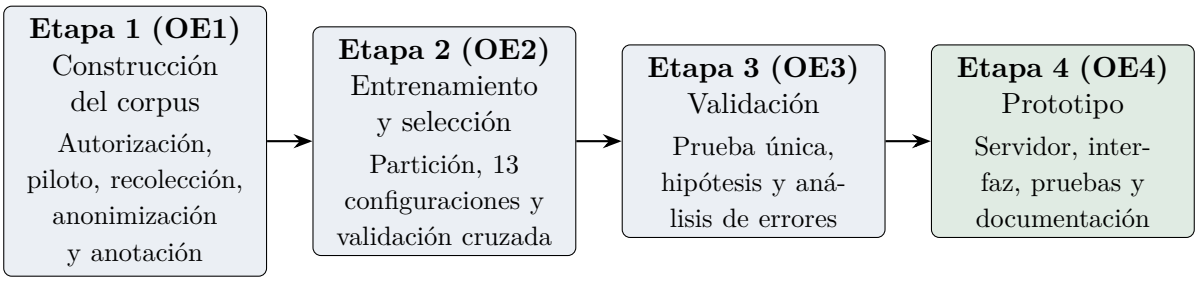


Nota. Elaboración propia.

3.3. Etapas del Desarrollo

La Figura 3 resume las cuatro etapas. Cada una corresponde a un objetivo específico y entrega un producto que la siguiente necesita.

Figura 3
Etapas del desarrollo del modelo



Nota. Elaboración propia.

3.3.1. Etapa 1: Construcción del corpus (OE1)

Primero se define para qué se usará el modelo y quién custodiará los datos, y se obtiene la aprobación del comité de ética y de la universidad. Los especialistas revisan la guía de anotación antes de empezar.

Luego se aplica el formulario a unos 40 estudiantes para comprobar que las preguntas se entienden y que la anonimización y la anotación funcionan. Con los ajustes

necesarios se abre la convocatoria principal, siempre voluntaria y sin acceder a conversaciones privadas ni a expedientes.

A cada relato recibido se le quitan nombres, teléfonos, correos, códigos y cualquier detalle que permita reconocer a alguien, y se reemplazan por marcadores como `[PERSONA]` o `[CURSO]`. Después, dos anotadores etiquetan cada relato por separado y se calcula su acuerdo con el kappa de Cohen (Ecuación 15); un especialista resuelve los casos en que no coinciden. La etapa termina con el corpus anotado y su hoja de datos (Gebru et al., 2021).

3.3.2. Etapa 2: Entrenamiento y selección del modelo (OE2)

Se reserva alrededor del 20 % de los participantes para la prueba final y el 80 % restante se usa para el desarrollo, manteniendo la proporción de relatos con y sin acoso. Antes de entrenar cualquier modelo se define la lista de palabras de la línea base léxica (Ecuación 10).

Con los datos de desarrollo se entrenan las 13 configuraciones del diseño. Los relatos se representan con TF-IDF (Ecuación 3) para la regresión logística, la SVM lineal y Naïve Bayes (Ecuaciones 4 a 7), y con la representación contextual de BETO (Ecuaciones 8 y 9). Cada modelo se prueba sin tratamiento del desbalance, con ponderación de clases (Ecuación 11) y, en el caso de TF-IDF, con SMOTE (Ecuación 12). Los hiperparámetros se ajustan con validación cruzada agrupada de cinco pliegues. Se elige el modelo con mayor macro F1; si dos empatan, se prefiere el de mayor F1 en la clase positiva y, después, el más sencillo. El Algoritmo 1 resume el procedimiento.

Algoritmo 1 Entrenamiento, selección y validación del modelo

Entrada: Corpus anotado D con etiqueta e identificador de participante; configuraciones $\mathcal{C}$
Salida: Modelo seleccionado m^* y sus métricas en la prueba
Agrupar relatos duplicados o casi idénticos
Dividir D por participante en D_{dev} (80 %) y D_{test} (20 %) ▷ D_{test} no se toca
Crear 5 pliegues por participante dentro de D_{dev}
for all $c \in \mathcal{C}$ y las dos líneas base **do**
    for all pliegue k **do**
        Ajustar la representación y el remuestreo **solo** con el entrenamiento del pliegue k
        Entrenar c y registrar macro F1 y F1 positivo en la validación del pliegue k
    end for
    Calcular el promedio y la dispersión de las métricas de c
end for
$m^* \leftarrow$ configuración con mayor macro F1
Reentrenar m^* con todo D_{dev}
Evaluar una sola vez en D_{test}: P, R, F_1, macro F_1 y matriz de confusión
return m^* y sus métricas con intervalos del 95 %

3.3.3. Etapa 3: Validación del modelo (OE3)

El modelo elegido y las líneas base se prueban una sola vez con los relatos reservados. Se calculan la precisión, la exhaustividad, el F1 y el macro F1 (Ecuaciones 13 y 14), con sus intervalos de confianza por *bootstrap*, y se contrastan las hipótesis con la prueba de McNemar (Ecuación 16) según los criterios de la Tabla 2. Después se revisan uno por uno los relatos en los que el modelo se equivocó, para entender por qué: negaciones, citas, insinuaciones, falta de contexto, expresiones locales o ironía.

3.3.4. Etapa 4: Implementación del prototipo (OE4)

Se implementa el prototipo descrito en la siguiente sección: el servidor con FastAPI que carga el modelo validado y calcula las explicaciones con SHAP (Ecuación 17), y la interfaz en React. Luego se verifica con relatos de ejemplo que el prototipo dé las mismas predicciones que el modelo y que cumpla cada requisito funcional. El modelo se documenta con una ficha técnica (Mitchell et al., 2019) y, por último, se vuelve a ejecutar todo el proceso desde cero para comprobar que se obtienen las mismas métricas.

3.4. Prototipo de Apoyo a la Revisión

El prototipo será una aplicación web que funciona en un equipo local. Tendrá un servicio en Python con FastAPI, que carga el modelo validado, y una interfaz en React para quien revisa los relatos. El usuario pega un relato, el sistema le avisa si detecta posibles datos personales y luego muestra si el relato describe acoso, con qué probabilidad y qué palabras influyeron más en esa decisión según SHAP (Lundberg & Lee, 2017). Los relatos analizados no se guardan ni se envían a ningún servicio externo. Las Tablas 11 y 12 listan sus requisitos.

Tabla 11
Requisitos funcionales del prototipo

Código	**Requisito**
RF01	Recibir un relato en español a través de un campo de texto.
RF02	Avisar si el relato contiene posibles datos personales, como nombres, correos, teléfonos o códigos.
RF03	Clasificar el relato como *con acoso sexual* o *sin acoso sexual* con el modelo validado.
RF04	Mostrar la probabilidad de que el relato describa acoso sexual.
RF05	Mostrar las palabras que más aumentan y disminuyen esa probabilidad.
RF06	Mostrar siempre un aviso de que el resultado es un apoyo a la revisión y no una decisión.

Nota. Elaboración propia.

Tabla 12
Requisitos no funcionales del prototipo

Código	**Requisito**
RNF01	Privacidad: procesar los relatos en el equipo local, sin guardarlos ni enviarlos fuera.
RNF02	Fidelidad: dar las mismas predicciones que el modelo validado.
RNF03	Rendimiento: responder lo bastante rápido para usarse en una revisión interactiva en una computadora común.
RNF04	Mantenibilidad: código versionado, con las dependencias y la versión del modelo registradas.

Nota. Elaboración propia.

3.5. Resultados Esperados

Al terminar la investigación se espera contar con:

- Una guía de anotación revisada por especialistas y un informe del acuerdo entre anotadores.
- Un corpus anonimizado de relatos, de acceso restringido, con su hoja de datos.
- Un modelo de aprendizaje automático que detecte acoso sexual mejor que las líneas base, con su ficha técnica y el análisis de sus errores.
- El código del proceso completo, versionado y acompañado de datos de ejemplo.
- Un prototipo funcional que apoye a las oficinas de orientación y atención de la universidad en la revisión de relatos, siempre bajo el criterio de su personal y dentro de los procedimientos que establece la normativa (Ministerio de la Mujer y Poblaciones Vulnerables, 2019).

Conclusiones

1. El problema es real y cercano: en la UNSAAC, el 77,5 % de los estudiantes encuestados vivió al menos una manifestación de hostigamiento sexual y menos del 1 % lo denunció (Gutiérrez de Alarcón et al., 2022). Gran parte de lo que ocurre nunca llega a conocimiento de la universidad.

2. Los antecedentes muestran que el aprendizaje automático ya se usa para detectar contenidos relacionados con el acoso, también en español. Sin embargo, esos trabajos usan publicaciones de redes sociales o mensajes; ninguno trabajó con relatos de estudiantes universitarios ni en el contexto peruano, y algunos se evaluaron de forma que puede sobrestimar sus resultados.

3. CRISP-DM ofrece una ruta clara para construir el modelo, desde la recolección de relatos hasta el prototipo, y permite incorporar los cuidados éticos que exige trabajar con información sensible.

4. El diseño experimental planteado permite comparar los modelos candidatos con las mismas condiciones y contrastar las hipótesis frente a una línea base léxica y una mayoritaria.

5. El principal aporte para la Ingeniería Informática y de Sistemas será un modelo validado para detectar acoso sexual en relatos en español, integrado en un prototipo que apoya la revisión humana.

Recomendaciones

1. Obtener la aprobación del comité de ética y de la universidad antes de recoger cualquier relato.

2. Validar la guía de anotación con especialistas en acoso sexual y en la normativa vigente, y aplicar el piloto antes de la recolección principal.

3. Coordinar con las instancias de prevención y atención del hostigamiento sexual de la universidad la difusión de la convocatoria y la información de ayuda que incluirá el formulario.

4. Usar las predicciones del modelo solo como apoyo a la revisión humana, nunca para sancionar ni para identificar responsables.

5. En investigaciones futuras, ampliar el corpus a otras universidades y a relatos en quechua, y clasificar también el tipo de acoso.

Bibliografía

Aguirre Soto, J., Ávila Gonzales, H., & Bravo Saines, V. (2022). Uso de una herramienta de NLP aplicada a la detección del ciberacoso en Twitter. *Innovación y Software*, *3*(2), 81-90. https://n2t.net/ark:/42411/s9/a65

Bondestam, F., & Lundqvist, M. (2020). Sexual harassment in higher education – a systematic review. *European Journal of Higher Education*, *10*(4), 397-419. https://doi.org/10.1080/21568235.2020.1729833

Bull, A., & Bradley, A. (2026). Who is experiencing faculty/staff-student sexual misconduct in UK higher education? *Journal of Gender-Based Violence*. Publicación anticipada en línea. https://doi.org/10.1332/23986808Y2025D000000120

Cañete, J., Chaperon, G., Fuentes, R., Ho, J.-H., Kang, H., & Pérez, J. (2020). Spanish pre-trained BERT model and evaluation data. *Practical ML for Developing Countries Workshop (PML4DC) at ICLR 2020*. https://arxiv.org/abs/2308.02976

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321-357. https://doi.org/10.1613/jair.953

Congreso de la República del Perú. (2003, 27 de febrero). *Ley N.º 27942, Ley de prevención y sanción del hostigamiento sexual*. Diario Oficial El Peruano.

Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, *20*(3), 273-297. https://doi.org/10.1007/BF00994018

Cumba Armijos, P. D. (2018). *Predicción de ataques de cyber bullying mediante técnicas de aprendizaje profundo apoyándose en un corpus de entrenamiento para la clasifi-*

cación de texto en español [Tesis de maestría, Universidad Internacional SEK]. Repositorio Digital UISEK. https://repositorio.uisek.edu.ec/handle/123456789/3224

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 4171-4186. https://doi.org/10.18653/v1/N19-1423

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, *10*(7), 1895-1923. https://doi.org/10.1162/089976698300017197

Dutta, A., Banducci, S., & Camargo, C. Q. (2025). Divided by discipline? A systematic literature review on the quantification of online sexism and misogyny using a semi-automated approach. *Scientometrics*, *130*(9), 4915-4971. https://doi.org/10.1007/s11192-025-05410-2

Efron, B., & Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

Escobar Mercado, M., Gil, E., & Calvo López, C. (2022). Análisis de la dinámica, la estructura y el contenido de los mensajes de Twitter: Violencia sexual en #Cuéntalo. *EMPIRIA. Revista de Metodología de Ciencias Sociales*, (53), 89-110. https://doi.org/10.5944/empiria.53.2022.32614

Fielding, R. T. (2000). *Architectural styles and the design of network-based software architectures* [Tesis doctoral, University of California, Irvine]. https://ics.uci.edu/~fielding/pubs/dissertation/top.htm

Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daumé III, H., & Crawford, K. (2021). Datasheets for datasets. *Communications of the ACM*, *64*(12), 86-92. https://doi.org/10.1145/3458723

Gorissen, M., van den Berg, C. J. W., Ruiter, S., & Bijleveld, C. C. J. H. (2023). Sharing unwanted sexual experiences online: A cross-platform analysis of disclosures

before, during and after the #MeToo movement. *Computers in Human Behavior*, *144*, Artículo 107724. https://doi.org/10.1016/j.chb.2023.107724

Gutiérrez de Alarcón, R. D., Cuadra Moreno, M. L., Solano Coello, M. E., Paz Muro, E. S., Tapia Sánchez, C. D., Gutiérrez Alarcón, H. R., & Valencia Blanco, D. S. (2022). Prevalencia, reacciones y efectos del hostigamiento sexual en dos universidades públicas del Perú. *Revista de Investigación Estadística*, *4*(1), 36-46. https://revistas.unitru.edu.pe/index.php/REDIES/article/view/4382

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer. https://doi.org/10.1007/978-0-387-84858-7

Hernández-Sampieri, R., & Mendoza Torres, C. P. (2023). *Metodología de la investigación: las rutas cuantitativa, cualitativa y mixta* (2.ª ed.). McGraw-Hill Interamericana Editores.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, *6*(2), 65-70.

Imbaquinga Guaña, J. R., & Lara Anago, N. A. (2025). *Modelo para la detección y prevención de cibergrooming y cibersexting utilizando algoritmos de procesamiento de lenguaje natural y técnicas de clasificación en aprendizaje automático* [Tesis de grado, Universidad de las Fuerzas Armadas ESPE]. Repositorio Institucional ESPE. https://repositorio.espe.edu.ec/handle/21000/61636

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, *4*(9), Artículo 100804. https://doi.org/10.1016/j.patter.2023.100804

Karami, A., White, C. N., Ford, K., Swan, S., & Yildiz Spinel, M. (2020). Unwanted advances in higher education: Uncovering sexual harassment experiences in academia with text mining. *Information Processing & Management*, *57*(2), Artículo 102167. https://doi.org/10.1016/j.ipm.2019.102167

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, *33*(1), 159-174. https://doi.org/10.2307/2529310

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems 30*, 4765-4774.

McCallum, A., & Nigam, K. (1998). A comparison of event models for naive Bayes text classification. *AAAI-98 Workshop on Learning for Text Categorization*, 41-48.

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, *12*(2), 153-157. https://doi.org/10.1007/BF02295996

Ministerio de la Mujer y Poblaciones Vulnerables. (2019, 22 de julio). *Decreto Supremo N.º 014-2019-MIMP, que aprueba el Reglamento de la Ley N.º 27942, Ley de prevención y sanción del hostigamiento sexual*. Diario Oficial El Peruano.

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT* '19)*, 220-229. https://doi.org/10.1145/3287560.3287596

Mohammadi, H., Giachanou, A., & Bagheri, A. (2024). A transparent pipeline for identifying sexism in social media: Combining explainability with model prediction. *Applied Sciences*, *14*(19), Artículo 8620. https://doi.org/10.3390/app14198620

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., ... Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems 32*, 8024-8035.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Courna-

peau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, *12*, 2825-2830.

Ríos-Albert, E., Cerdán-Torregrosa, A., Espinar-Ruiz, E., Jaskulska, S., Jankowiak, B., Del Piccolo, L., Donisi, V., Dal Maso, F., Avery, S., Sousa, M., Silva, E., Neves, S., Stifter, V., Wallner, M., & Vives-Cases, C. (2026). "Sexual harassment definitely involves a hierarchical transgression": Key informants' discourses on sexual harassment in European universities. *PLOS ONE*, *21*(8), Artículo e0355556. https://doi.org/10.1371/journal.pone.0355556

Rodríguez-Sánchez, F., Carrillo-de-Albornoz, J., & Plaza, L. (2020). Automatic classification of sexism in social networks: An empirical study on Twitter data. *IEEE Access*, *8*, 219563-219576. https://doi.org/10.1109/ACCESS.2020.3042604

Rodríguez-Sánchez, F., Carrillo-de-Albornoz, J., Plaza, L., Gonzalo, J., Rosso, P., Comet, M., & Donoso, T. (2021). Overview of EXIST 2021: sEXism Identification in Social neTworks. *Procesamiento del Lenguaje Natural*, *67*, 195-207. https://doi.org/10.26342/2021-67-17

Salawu, S., He, Y., & Lumsden, J. (2020). Approaches to automated detection of cyberbullying: A survey. *IEEE Transactions on Affective Computing*, *11*(1), 3-24. https://doi.org/10.1109/TAFFC.2017.2761757

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems 30*, 5998-6008.

Wijaya, I. D., Putrada, A. G., & Oktaria, D. (2022). Overcoming data imbalance problems in sexual harassment classification with SMOTE. *International Journal on Information and Communication Technology*, *8*(1), 20-29. https://doi.org/10.21108/ijoict.v8i1.622

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., von Platen, P., Ma, C., Jernite,

Y., Plu, J., Xu, C., Le Scao, T., Gugger, S., ... Rush, A. (2020). Transformers: State-of-the-art natural language processing. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 38-45. https://doi.org/10.18653/v1/2020.emnlp-demos.6

Anexo A. Matriz de Consistencia

Tabla 13

Matriz de consistencia

Título: Desarrollo de un modelo de aprendizaje automático para la detección de acoso sexual en relatos de estudiantes de la UNSAAC

Problemas	Objetivos	Hipótesis	Variables	Indicadores
		General		
¿En qué medida el desarrollo de un modelo de aprendizaje automático permite la detección de acoso sexual en relatos de estudiantes de la UNSAAC, en comparación con una línea base de referencia?	Desarrollar un modelo de aprendizaje automático para la detección de acoso sexual en relatos de estudiantes de la UNSAAC, cuyo desempeño se evaluará mediante el macro F1 y la exhaustividad en relatos de prueba, frente a una línea base léxica.	El modelo de aprendizaje automático desarrollado detecta acoso sexual en relatos de estudiantes de la UNSAAC con un desempeño significativamente superior al de una línea base de referencia.	**VI:** modelo de aprendizaje automático (representación, algoritmo, tratamiento del desbalance). **VD:** detección de acoso sexual (desempeño global, clase positiva, errores).	Macro F1; precisión, exhaustividad y F1 de la clase positiva; diferencia frente a la línea base léxica (McNemar e IC 95 %).
		Específicos		
PE1: ¿Qué nivel de acuerdo entre anotadores se alcanza al construir un corpus anonimizado y anotado de relatos de estudiantes de la UNSAAC para entrenar el modelo de aprendizaje automático?	**OE1:** Construir un corpus anonimizado y anotado de relatos de estudiantes de la UNSAAC para entrenar y validar el modelo de aprendizaje automático, determinando el nivel de acuerdo entre anotadores.	**HE1:** El corpus de relatos de estudiantes de la UNSAAC, construido con anonimización y doble anotación, alcanza un acuerdo al menos sustancial ($\kappa \geq 0{,}61$).	Control: calidad del corpus.	Kappa de Cohen con IC 95 %; acuerdo porcentual; tasa de exclusión.
PE2: ¿Qué modelo de aprendizaje automático, y con qué tratamiento del desbalance de clases, logra el mejor desempeño en la detección de acoso sexual al ser entrenado y seleccionado sin fuga de información?	**OE2:** Entrenar y seleccionar el modelo de aprendizaje automático con mejor desempeño en la detección de acoso sexual, con y sin tratamiento del desbalance de clases, sin fuga de información.	**HE2:** El tratamiento del desbalance de clases, aplicado al entrenar los modelos de aprendizaje automático candidatos, incrementa su exhaustividad en la detección de acoso sexual.	VI: algoritmo y tratamiento del desbalance. Control: reproducibilidad.	Macro F1 de validación por configuración; exhaustividad con y sin tratamiento (IC 95 %).
PE3: ¿Qué desempeño alcanza el modelo seleccionado al validarlo en la detección de acoso sexual en relatos de estudiantes de la UNSAAC frente a una línea base de referencia, y qué errores comete?	**OE3:** Validar el desempeño del modelo seleccionado en la detección de acoso sexual en relatos de estudiantes de la UNSAAC frente a una línea base de referencia, analizando sus errores.	**HE3:** El modelo seleccionado, validado en los relatos de prueba, alcanza en la detección de acoso sexual una exhaustividad superior a la de la línea base léxica, incluso en relatos sin términos sexuales explícitos.	VD: desempeño en la clase positiva y errores.	Exhaustividad global y en relatos sin términos explícitos; McNemar con ajuste de Holm; errores por tipo.
PE4: ¿Cómo implementar un prototipo que aplique el modelo validado a nuevos relatos de estudiantes de la UNSAAC como apoyo a la revisión humana?	**OE4:** Implementar un prototipo que aplique el modelo validado a nuevos relatos de estudiantes de la UNSAAC como apoyo a la revisión humana.	**HE4:** El prototipo implementado reproduce las predicciones del modelo validado sobre nuevos relatos de estudiantes de la UNSAAC y cumple los requisitos funcionales definidos.	VD: detección de acoso sexual en relatos nuevos.	Coincidencia de predicciones con el modelo; porcentaje de requisitos funcionales aprobados.

Método. *Tipo:* aplicada, tecnológica. *Enfoque:* cuantitativo. *Alcance:* explicativo. *Diseño:* experimental computacional factorial con medidas repetidas. *Población:* estudiantes mayores de edad matriculados en la UNSAAC. *Muestra:* no probabilística, voluntaria; piloto de 40 relatos y 400 a 600 relatos válidos. *Instrumentos:* formulario de relato, ficha de anonimización, guía de anotación y registro de experimentos. *Desarrollo:* CRISP-DM en cuatro etapas, una por objetivo específico. *Análisis:* macro F1 y métricas por clase; McNemar con ajuste de Holm; IC 95 % por remuestreo; $\alpha = 0{,}05$.

Nota. PE: problema específico; OE: objetivo específico; HE: hipótesis específica; VI: variable independiente; VD: variable dependiente; IC: intervalo de confianza. Elaboración propia.

Anexo B. Guía de Anotación

La etiqueta describe lo que cuenta el relato; no confirma hechos ni señala responsables. Los anotadores no deben suponer el género, la orientación, el consentimiento ni la intención de nadie a partir de estereotipos.

Tabla 14
Etiquetas y criterios de anotación

Etiqueta	**Criterio**	**Tratamiento**
Con acoso sexual	El relato describe una conducta sexual no deseada, una presión o un condicionamiento sexual, con contexto suficiente	Clase positiva (1)
Sin acoso sexual	El relato tiene contexto suficiente y no cumple los criterios anteriores	Clase negativa (0)
Información insuficiente	No se puede saber qué ocurrió, en qué contexto o si se trata de una cita	Se revisa con un especialista; si persiste la duda, se excluye

Nota. Elaboración propia.

Reglas de decisión:

- Distinguir entre lo que el estudiante vivió y lo que cita o cuenta de otros.
- Revisar las negaciones y las menciones a hechos que no ocurrieron.
- Tomar en cuenta una relación de dependencia (docente, jefe de práctica, tutor) solo si aparece en el relato.
- No exigir que la conducta se repita ni que el agresor tenga más jerarquía.
- No etiquetar como acoso una conversación educativa sobre sexualidad solo por las palabras que usa.
- Ante la duda, marcar *información insuficiente* en lugar de forzar una etiqueta.

Anexo C. Instrumento de Recolección

El formulario tiene tres partes: el consentimiento informado, una verificación de que la persona es mayor de edad y está matriculada, y un campo para escribir el relato. No pide nombres, capturas de chats, números de contacto, códigos de estudiante ni datos de terceros.

Consigna:

> *Si deseas participar, cuéntanos con tus propias palabras una situación de tu vida universitaria que quieras compartir. Puede ser algo que te haya resultado incómodo o problemático, o simplemente una interacción cotidiana. Explica qué pasó y el contexto que creas necesario, sin incluir nombres, fechas exactas ni detalles que permitan reconocer a alguien. Puedes dejar de responder en cualquier momento.*

Al final del formulario se indica que este no es un canal de denuncia y se incluyen los datos de contacto de las oficinas de orientación y atención de la universidad.